分类号

江南大学

硕士学位论文

题　　目：遗传算法的研究与应用——基于3PM交叉算子的退火遗传算法及应用研究

英文并列题目：The Research and Application of Genetic Algorithm —— 3PM Crossover Operator Based Annealing Genetic Algorithm and the Research of Its Application

研　究　生：王银年

专　　业：计算机应用技术

研究方向：人工智能与模式识别

导　　师：葛洪伟

指导小组成员：

学位授予日期：2009.8.14

答辩委员会主席：吴小俊

江南大学

地址：无锡市蠡湖大道1800号

二〇〇九年八月

中国知网 https://www.cnki.net

独 创 性 声 明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含本人为获得江南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

签　　名：王银年　　日　　期：2009.8.14

关于论文使用授权的说明

本学位论文作者完全了解江南大学有关保留、使用学位论文的规定：江南大学有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅，可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文，并且本人电子文档的内容和纸质论文的内容相一致。

保密的学位论文在解密后也遵守此规定。

签　　名：王银年　　导师签名：葛洪伟

日　　期：2009.8.14

中国知网 https://www.cnki.net

摘　要

遗传算法是一种借鉴生物界自然选择和进化机制发展起来的高度并行、随机、自适应搜索算法。它的研究历史比较短，早期是一种试图解释自然系统中生物的复杂适应过程入手，模拟生物进化的机制来构造人工系统的模型。近年来世界范围形成的进化计算热潮，计算智能已作为人工智能研究的一个重要方向，以及后来的人工生命研究兴起，使遗传算法受到广泛的关注。

鉴于遗传算法存在着收敛速度慢或易出现“早熟”现象，本文对遗传算法进行改进，针对 TSP 问题提出贪心 3PM 交叉算子，同时对模拟退火算法进行改进，并将改进后的两种算法相结合，形成一种基于 3PM 交叉算子的模拟退火遗传算法(GCBSAGA)。主要研究工作如下：首先介绍了遗传算法国内外的研究现状，以及现有的遗传算法与模拟退火算法相结合的现有情况。其次，在阐述遗传算法基本概念、原理、方法、步骤的基础上，针对巡回旅行商问题(TSP)提出一种基于 3PM 交叉算子的模拟退火遗传算法(GCBSAGA)。在新算法中，一方面，对遗传算法进行了改进，先改进了它的构架，再引入判断搜索效率的条件，一旦搜索效率下降，便终止遗传算法，这样便保留了遗传算法前期全局高效的搜索，屏弃了后期搜索能力低的毛病。然后又提出了一种新的交叉算子——贪心 3PM 交叉算子，这种算子不但考虑到了城市位置的关系，更重要的是考虑到了城市之间边的关系。采用三个父代产生子代的方法，能够得到更优的边信息，而且采用双向轮转的方法，使子完全地继承了父代的边的信息。而且对产生的子代还进行退火选择，从而将温度这一概念加入到遗传算法中，这样使子代基本不会出现退化现象。通过实验也可以看出，贪心 3PM 交叉算子收敛速度非常快，搜索能力极高。另一方面，对模拟退火算法进行改进，它使用的初始解就是遗传算法结束后得到的全局较优解，即对全局较优解进行独立退火，这样使得原本盲目搜索的模拟退火算法固定在有希望的区域里搜索，大大提高了搜索效率。模拟退火算法使用的初始温度也是遗传算法结束后的温度，这样高温时使用遗传算法，发挥它高效的全局搜索能力，低温时使用模拟退火算法，发挥它强大的局部搜索能力。然后选用国际公认的 TSP 库的数据进行测试，找到了比 TSP 库提供的最优解更优的解，证明了新算法的有效性。最后把新算法运用到配送和回收一体化的车辆路径问题这一实际问题中，并且针对问题的特殊性加入了编码解码机制，通过实验和对比验证了 GCBSAGA 算法在解决此类问题时的高效性。

关键词：遗传算法　退火选择　模拟退火算法　巡回旅行商问题　贪心 3PM 交叉算子

中国知网　https://www.cnki.net

Abstract

Genetic algorithm is a highly parallel,randomized and adaptive search algorithm, developmenting on natural selection and evolutionary of biological mechanisms. Its research history is short, early it is a constructed artificial system model of simulating the mechanisms of biological evolution from attempting to explain the complexity process of biological in the natural system. Formed in recent years around the world boom of evolutionary computation, computational intelligence became one of the major directions of artificial intelligence research, as well as the subsequent rise of artificial life research, so that genetic algorithms is concerned broad.

Genetic algorithms in view of the existence of slow convergence or prone to "premature" phenomenon, this paper improved genetic algorithms and advanced greedy 3PM crossover operator for TSP problems, at the same time improved the simulated annealing algorithm and two improved algorithms combination ,formed Greedy 3PM Crossover operator Based Simulated Annealing Genetic Algorithms(GCBSAGA). The main research work is listed as follows: Firstly, introduced genetic algorithm research at home and abroad, as well as the existing genetic algorithm and simulated annealing algorithm to combine the existing situation. Secondly, the genetic algorithm in the basic concepts, principles, methods, steps, based on the tour for the traveling salesman problem (TSP), advance Greedy 3PM Crossover operator Based Simulated Annealing Genetic Algorithms(GCBSAGA). In the new algorithm, on the one hand, the improved genetic algorithm, first to improve its framework, and then search to determine the efficiency of the introduction of the conditions, once the search efficiency, then the termination of genetic algorithm, so the genetic algorithm to retain the overall costeffective search, reject the latter part of the problem of low search capabilities. Then goes on to suggest a new crossover operator—greedy 3PM crossover operator, the operator will not only take into account the relationship between the city locations, more importantly, takes into account the relationship between cities edge. The method using the three parents produce offspring, can be better side information, and the use of bidirectional rotation of the ways in which subcompletely inherited parent information edge. But also to the offspring resulting from annealing was also carried out, thus the temperature of the concept will be added to the genetic algorithm, so that does not appear to make the basic offspring degradation. Can be seen through the experiment, greedy crossover operator 3PM very fast convergence, high search capabilities. On the other hand, simulated annealing algorithm, which uses genetic algorithm the initial solution is obtained after the better overall solution, that is better overall solution to conduct an independent annealing, which makes the blind search of the original simulated annealing algorithm fixed promising search area has greatly enhanced the efficiency of the search. Simulated annealing algorithm is used in genetic algorithm initial temperature after the end of the temperature, so that the use of high-temperature genetic algorithm, to play its highly efficient global search capability, the use of low-temperature simulated annealing algorithm, to play its strong local search ability. And then selected the internationally recognized TSP in the database for testing and found the TSP library than the optimal solution to provide better

中国知网 https://www.cnki.net

solutions, proved that the new algorithm. Finally, the new algorithm applied to the integration of distribution and recovery of the vehicle routing problem of the practical problems, and adding a codec mechanism for the specificity of the problem, through experiments and contrast GCBSAGA algorithm verified to solve such problems in the efficiency.

Keywords: genetic algorithm, annealing choice, simulated annealing algorithm, TSP, greedy 3PM crossover operator

中国知网 https://www.cnki.net

目　录

摘　要 ..... **I**

ABSTRACT ..... **II**

第一章 绪 论 **1**

1.1 课题的背景 1
1.2 研究现状 2
1.3 本文研究内容 3
1.4 论文结构 3

第二章 遗传算法概述 **4**

2.1 生物进化与遗传算法 4
2.1.1 生物进化概述 4
2.1.2 遗传算法概述 4
2.2 进化计算 5
2.3 遗传算法的基本概念 7
2.4 遗传算法的模式定理 8
2.5 欺骗问题 10
2.6 遗传算法的应用概述 11

第三章 模拟退火遗传算法 **14**

3.1 模拟退火算法 14
3.1.1 模拟退火算法概述 14
3.1.2 模拟退火算法的基本步骤 14
3.2 基本遗传算法 16
3.2.1 基本遗传算法步骤 16
3.2.2 遗传算法染色体编码 16
3.2.3 适应度函数 18
3.2.4 遗传算子 19
3.3 模拟退火遗传算法 22
3.3.1 国外研究情况 22
3.3.2 国内研究情况 23

第四章 求解 TSP 问题的 GCBSAGA 算法 **24**

4.1 巡回旅行商问题 24
4.1.1 顺序表示与交叉 25
4.1.2 路径表示与交叉 26
4.2 求解 TSP 问题的 GCBSAGA 算法 27
4.2.1 遗传算法的改进 28
4.2.2 模拟退火算法的改进 31
4.2.3 基于 GCBSAGA 的 TSP 问题求解 32
4.3GCBSAGA 算法的分析 34
4.3.1 混合遗传算法的构造原则 34
4.3.2 算法 GCBSAGA 的优点 35
4.4 交叉算子收敛性分析 35
4.5 实验结果与分析 39

中国知网 https://www.cnki.net

第五章 GCBSAGA 算法在配送和回收一体化车辆路径中的应用 43
5.1 VRPSDP 问题概述 43
5.2VRPSDP 问题描述 44
5.2.1VRPSDP 问题描述 44
5.2.2 可行性解 44
5.2.3 弱可行性解转化为强可行性解 45
5.3 求解 VRPSDP 的 GCBSAGA 算法 45
5.3.1 遗传算法的编码解码机制及初始种群 45
5.3.2 模拟退火算法的变异方法 45
5.3.3 求解 VRPSDP 的 GCBSAGA 算法流程 46
5.4 实验结果与分析 47
第六章 结论与展望 50
6.1 论文小结 50
6.2 论文的主要创新点 50
6.3 论文存在的问题以及未来工作的展望 51
致 谢 52
参考文献 53
附录： 作者在攻读硕士学位期间发表的论文 58

中国知网 https://www.cnki.net

第一章 绪 论

1.1 课题的背景

当前科学技术正进入多学科互相交叉、互相渗透、互相影响的时代，生命科学与工程科学的交叉、渗透和相互促进是其中一个典型例子，也是近代科学技术发展的一个显著特点。遗传算法的蓬勃发展正体现了科学发展的这一特点和趋势。

制造机器智能一直是人类的梦想，人们为此付出了巨大的努力。人工智能技术的出现，就是人们得到的成果。众所周知，在人工智能领域中，有不少问题需要在复杂而庞大的搜索空间中寻找最优解或准优解。像货朗担问题和规划问题等组合优化问题就是典型的例子。在求解此类问题时，若不能利用问题的固有知识来缩小搜索空间则会产生搜索的组合爆炸。因此，研究能在搜索过程中自动获得和积累有关搜索空间的知识，并能自适应地控制搜索过程，从而得到最优解或准有解的通用搜索算法一直是令人瞩目的课题。

最优化问题通过数学符号表示之后都可分为两类：函数优化问题和组合优化问题，其中函数优化问题的对象是一定区间内的连续变量，而组合优化问题的对象则是空间中离散的状态。目前,一些精确算法和智能优化算法在解决这些优化问题方面发挥了重要作用。 精确算法包括线性规划、动态规划、整数规划和分支定界等等，其算法计算复杂性一般很大，只适应于求解小规模问题，在工程中往往不实用。智能优化算法，主要包括模拟退火算法[1](Simulated Annealing)、遗传算法[2](Genetic Algorithms)、禁忌搜索算法[3](Tabu Search)、蚁群算法[4](Ant Colony Algorithm)和神经网络方法[5][6](Neural Networks)，从任一解出发，对其领域的不断搜索和当前解的替换来实现优化，根据搜索行为不同，又分为局部搜索法如贪婪法，指导性搜索法如智能优化算法，这些算法模仿了自然界的各种过程以及人的思维活动来对整个搜索过程进行指导。

遗传算法具有良好的全局搜索能力[7]，可以快速地将解空间中的全体解搜索出，而不会陷入局部最优解的快速下降陷阱；并且利用它的内在并行性，可以方便地进行分布式计算，加快求解速度。但是遗传算法的局部搜索能力较差[8]，导致单纯的遗传算法比较费时，在进化后期搜索效率较低。在实际应用中，遗传算法容易产生早熟收敛的问题。采用何种选择方法既要使优良个体得以保留，又要维持群体的多样性，一直是遗传算法中较难解决的问题。

模拟退火算法虽具有摆脱局部最优解的能力[9]，能够以随机搜索技术从概率的意义上找出目标函数的全局最小点。但是，由于模拟退火算法对整个搜索空间的状况了解不多，不便于使搜索过程进入最有希望的搜索区域，使得模拟退火算法的运算效率不高。模拟退火算法对参数（如初始温度）的依赖性较强，且进化速度慢。

利用模拟退火算法的局部高效的搜索能力能够克服遗传算法早熟的问题，同是利用遗传算法也能克服模拟退火算法的全局搜索效率低的问题。两种算法的相互补充，从而提高了算法的效能，更好的为实际问题服务。

中国知网 https://www.cnki.net

1.2 研究现状

遗传算法(Genetic Algorithm, GA)是近年来迅速发展起来的一种全新的随机搜索与优化算法。它是由美国密执安大学 J. Holland 教授提出的一类借鉴生物界自然选择和自然遗传机制的随机化搜索算法。它起源于达尔文的进化论, 是模拟达尔文的遗传选择和自然淘汰的生物进化过程的计算模型。遗传算法的研究引起了国内外学者的关注。自 1985 年以来，国际上已召开了多次遗传算法的学术会议和研讨会，国际遗传算法学会组织召开的 ICGA(International Conference on Genetic Algorithms) 会议和 FOGA(Workshop on Foundation of Genetic Algorithms)会议，为研究和应用遗传算法提供了国际交流的机会。

遗传算法的主要特点是群体搜索策略和群体中个体之间的信息交换, 搜索不以梯度信息为基础。它尤其适用于处理传统搜索方法难于解决的复杂和非线性问题, 可广泛应用于组合优化、机器学习、自适应控制、规划设计和人工生命等领域。作为一种全局优化搜索算法, 遗传算法以其简单通用、鲁棒性强、适于并行处理以及应用范围广等特点, 使其成为 21 世纪智能计算核心技术之一。进入 80 年代, 遗传算法迎来了兴盛发展时期, 无论是理论研究还是应用研究都成了十分热门的话题

近年来，遗传算法已被成功地应用于经济答理、交通运输、工业设计等不同领域. 解决了许多问题。例如，可靠性优化、流水车间调度、作业车间调度、机器调度、设备布局设计、图像处理以及数据挖掘等。

模拟退火算法来源于固体退火的原理[10]，其最初的思想由 Metropolis 在 1953 年提出，Kirkpatrick 在 1983 年成功地将其应用于组合最优化问题中。出发点是基于物理中固体物质的退火过程与一般组合优化问题之间的相似性。在对固体物质进行退火处理时，通常是先将它加温熔化，固体内部粒子随温升变为无序状，内能增大，使其中的粒子可以自由运动，然后降温，而徐徐冷却时粒子渐趋有序，在每个温度上都达到平衡态，最后在常温时达到基态，内能减为最小，粒子就逐渐形成低能态的晶体。如果凝结点附近温度下降足够慢，那么固体物质一定能够形成最低能量的状态。

目前已有一些将模拟退火算法与遗传算法相结合的方法。比如文献[11]中，通过模拟退火方法来控制变异概率（$Pm=\exp(-\theta m/T)$ ）的选取，通过模拟退火方法来控制交叉后子个体替代父个体的概率，但是这两种办法均不能充分的利用模拟退火算法强大的局部搜索能力。文献[12][13]中，利用遗传算法的特点来改变模拟退火的性能，首先通过 GA 来进化一个种群，然后再通过 SA 进一步调整优化解，这是对整个种群进行退火，没有能很好的利用 GA 得到的全局信息。而国内的遗传退火进化算法[14][15][16]，大多数是使用文献[17]中的方法。先取一些随机解构成种群，再对每个个体进行退火处理。由模拟退火接受的新解构成新的种群，再用 GA 的选择、交叉、变异进行处理。而退火算法是局部搜索算法，所得个体有可能是局部极小值，如果再从这个新种群中进行双亲选择，很容易陷入局部极小值，出现“早熟”现象。

中国知网 https://www.cnki.net

1.3 本文研究内容

本文通过对遗传算法、模拟退火算法的分析和改进，并将这两种算法结合，提出一种基于贪心 3PM(Parents Mating)交叉算子的模拟退火遗传算法（Greedy 3PM Crossover operator Based Simulated Annealing Genetic Algorithms，GCBSAGA），该算法不同于目前已有的算法。本文首先对遗传算法进行改进，包括终止条件的改进、引入温度的概念、提出了针对 TSP 问题的贪心 3PM 交叉算子等，使得遗传算法全局搜索效率明显提高，很快就能找出全局较优解。然后，对常规的模拟退火算法进行改进，将遗传算法得出的全局较优解作为模拟退火算法的初始解，使得它一开始就落入最有希望的搜索区域，大大缩小搜索范围，提高搜索效率。而且还对其中的冷却进度表进行优化，特别是温度方面，使用的是遗传算法结束后的温度，即高温时，用遗传算法找出全局较优解，低温时使用模拟退火算法，使得其接受退化个体的概率大大减小，一代一代向前发展。最后，将模拟退火算法嵌入到遗传算法中。其过程是随机产生一组初始群体，通过选择、交叉、变异等改进的遗传算子来产生一组新的个体，这样不断循环，直到产生的新群体的最优个体比父代差，之后选择最优个体，独立的对其进行模拟退火操作，如此反复迭代进行，直到满足某个终止条件为止。模拟退火遗传算法首先具有了 GA 的全局搜索能力，其次具有了 SA 的局部搜索能力，同时还能使 SA 算法充分利用 GA 的全局信息，对全局解空间有了详细了解。经验证，该算法在进化初期，使用遗传算法，温度较高，使得 GA 避免产生早熟收敛，增强了 GA 的全局收敛性；在进化后期，使用模拟退火算法，温度较低，使得 SA 算法具有较强的爬山性能，加快了算法的收敛速度。最后针对 TSP(Traveling Salesman Problem) 问题选用国际公认的 TSPLIB 库中的几个实例进行测试，均取得很好的效果，有的实例还找到了比 TSPLIB 提供的路径更优的路径。本文最后又把 GCBSAGA 运用到配送和回收一体化的车辆路径问题（Vehicle Routing Problem with Simultaneous Delivery and Pickup，VRPSDP）这一实际问题中，并取得了很好的效果。

1.4 论文结构

文共分六章。第二章简单介绍遗传算法，主要介绍了遗传算法的起源与发展、与生物进化的密切关系、进化计算、基本定理和应用情况。第三章介绍了模拟退火遗传算法，包括模拟退火相关的基本知识、基本遗传算法的步骤、每一步中常见的方法和问题、遗传算子以及模拟退火遗传算法目前的研究情况。第四章对遗传算法和模拟退火算法进行了算法分析并对其进行改进，提出了一种新的交叉算子—贪心 3PM(Parents Mating)交叉算子，并将改进后的两种算法相结合，形成一种基于贪心 3PM 交叉算子的模拟退火遗传算法(GCBSAGA)，并通过实验与分析，得出了这两种改进算法相结合的有效性。第五章则把 GCBSAGA 算法运用到配送和回收一体化的车辆路径问题(VRPSDP)中，这是一个非常具有实际运用价值的问题。第六章总结了本文的创新点和不足，并对以后的工作进行展望。

中国知网 https://www.cnki.net

第二章 遗传算法概述

2.1 生物进化与遗传算法

2.1.1 生物进化概述

1)生物进化的发展

19 世纪以来，人们通过农牧业的杂交育种，给遗传学的产生和发展积累了丰富的经验和资料。奥地利植物学家 G.Mendel 系统地概括和总结前人的经验[18]，于 1866 年发表了著名的论文《植物杂种实验》，阐明了生物的遗传规律，是历史上公认的实验遗传学创始人。

19 世纪中叶，英国博物学家达尔文《物种起源》一书出版。达尔文以自然选择为中心, 用丰富事实从变异、遗传、选择、生存和适应等方面论证了生物的进化。尤其重要的是说明了生物是怎样进化的(即自然选择在生物进化中所起的作用)。达尔文学说是对进化论研究成果全面的、系统的科学总结, 也是现代进化论的主要理论基础。

此后,荷兰植物学家、遗传学家佛里斯观察月见草变异, 经多年研究, 认为生物的进化起因于突变, 并于 1901～ 1903 年出版《突变理论》，W.L.Johannse 提出的基因概念等，都对进化论的发展提供了论证。本世纪初期，美国 T.H.Morgen 通过遗传学与细胞学的结合奠定了基因理论。

2)生物进化的基本特点

在我们生存的自然界里，生命千姿百态，万物相互依存。数亿年的进化，使各种生物基本适应现有环境生存下去，并繁衍后代，后代也会更适应环境。虽然进化的过程曲折变化的，进化的结果也各不一样，但所有生物的进化都具有一些共同的特点：

(1)进化的发生地点是信息载体，即染色体(Chromosome)，而不是被编码的生物个体(Individual)上。

(2)染色体能被复制，成功适应环境的被编码个体的染色体有更多的机会进行复制，形成有优势的后代。

(3)染色体能产生突变，使子代染色体不同于母代。

2.1.2 遗传算法概述

遗传算法是一类借鉴生物界的进化规律（适者生存，优胜劣汰遗传机制）演化而来的自适应概率性随机化迭代搜索算法。1975 年，美国 Michigan 大学的 J.H.Holland 教授在从事机器学习时注意到，学习不仅可以通过单个生物体的适应来完成，而且可以通过一个种群的许多进化适应来加以实现，Kenneth De Jong 将这种算法用来解决优化问题。

Holland 研究 GA 是从设计和实现一种能应付变化的、不确定环境的鲁棒性好的自适应系统开始。他认为这种系统的自适应是从所处的环境中随时得到反馈的函数关系，因而形成了我们今天称之为简单遗传算法的再生计划(Reproductive Plan)。这种简单的 GA 只是一类具有固定种群(Population)规模、个体用固定长度的基因链的抽象模型。根

中国知网 https://www.cnki.net

据适应度(Fitness)来随机地选择双亲，并按交叉(Crossover)和变异(Mutation)算子来产生新的种群。

遗传算法的特点是它的算法中不包含待解决问题所持有的形态。它是从改变基因的配置来实现问题的整体优化的，因而属于自下而上的优化方法。类似于生物的进化过程，遗传算法处理的是变量集合的编码而非变量本身。它直接对结构对象进行操作，不存在求导和函数连续性的限定；具有内在的隐并行性和更好的全局寻优能力；采用概率化的寻优方法，能自动获取和指导优化的搜索空间，自适应地调整搜索方向，不需要确定的规则。遗传算法的这些特点已被人们广泛地应用于组合优化、机器学习、信号处理、自适应控制和人工生命等领域。它是现代有关智能计算中的关键技术之一。

2.2 进化计算

进化计算[19](Evolutionary Computation，简记为 EC)是自 60 年代开始发展的一门新兴学科。它是指以进化原理为仿真依据，按优胜劣汰的自然选择优化规律和方法，在计算机上解决科技领域中难以用传统优化方法解决的优化计算问题的算法和程序，因此有时也称之为进化算法(Evolutionary Algorithms，EA)。

进化计算理论框架结构如图 2-1，与相关学科的关系如图 2-2 所示。

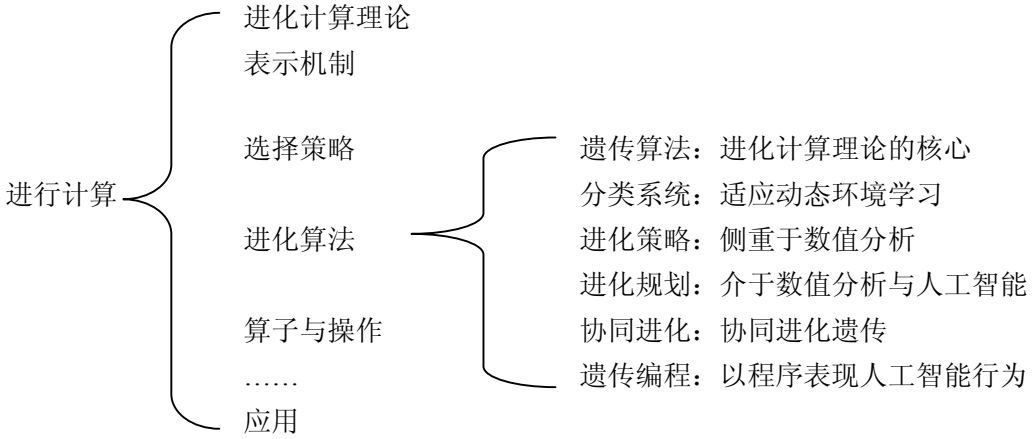

图 2-1　进化计算基本构架

Fig.2-1 The basic framework of evolutionary computation

中国知网 https://www.cnki.net

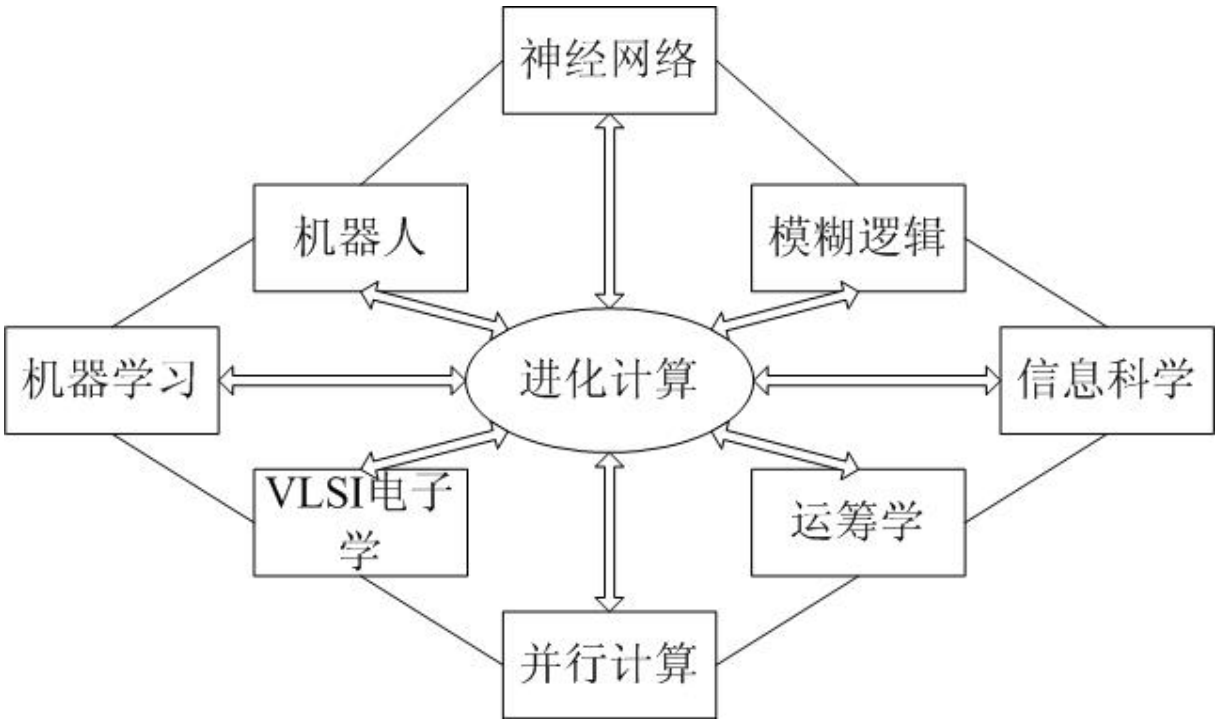

图 2-2　进化计算与相关科学的关系

Fig.2-2 the relationship is between evolutionary computation and related science

进化计算最初具有三大分支：遗传算法(Gentic Algorithm，GA)、进化规划(Evolutionary Programming，EP)和进化策略(Evolutionary Strategy，ES)。它们具有共同的本质，均来源于达尔文的进化论，分别强调了自然进行中的不同层面：遗传算法强调染色体的操作，进化策略强调了体级的行为变化，而进化规划则强调种群级上的行为变化。90 年代初，在遗传算法的基础上又形成了一个分支：遗传程序设计(Genetic Programming，GP)。虽然这几个分支在算法实现方面有一些差别，并且这些差别正逐渐缩小，它们一个共同的特点是借助生物进化的思想和原理来解决实际问题。作为进化计算理论体系的中心—遗传算法，其理论和方法不断地完善具有普遍的意义。现在进化算法 EC 的研究主要集中于遗传算法 GA、进化策略 ES 和进行规划 EP。国外在遗传编程 GP 方面的研究已形成规模，在国内，这方面的研究还处于在探索阶段。

1)遗传算法 GA 的基本思想

遗传算法[19](GA)是近几年发展起来的一种崭新的全局优化算法。1962 年霍兰德(Holland)教授首次提出了 GA 算法的思想，它的基本思想是基于 Darwin 进化论和 Mendel 的遗传演说。Darwin 进化论最重要的是适者生存的原理，它认为每一代种群总是向着前进方向发展，越来越适应环境。每一个个体都有继承前代的特性，但不是完全继承，会产生一些新特性。最终只有适应环境的特征才能被保留下来。Mendel 遗传学说最重要的是基因遗传原理，它认为遗传以密码方式存在细胞中，并以基因形式包含在染色体内。一条染色体中存在很多基因，每个基因有自己的位置并控制着外部特征；基因的产生和变异直接影响到个体的特性是否能适应环境。经过存优去劣的自然淘汰，适应性高的基因结构得以保存下来。

遗传算法正是借用了仿真生物遗传学和自然选择机理，通过自然选择、遗传、变异

中国知网 https://www.cnki.net

等作用机制，实现各个个体的适应性的提高。从某种程度上说遗传算法是对生物进化过程进行的数学方式仿真。这一点体现了自然界中"物竞天择、适者生存"进化过程。与自然界相似，遗传算法对求解问题的本身一无所知，从代表问题可能潜在解集的一个种群(population)开始，每一个种群则由经过基因(gene)编码(coding)的一定数目的个体(individual)构成。每个个体实际上是染色体(chromosome)带有特征的实体。把问题的解表示成染色体，并基于适应值来选择染色体，遗传算法所需要的仅是对算法所产生的每个染色体进行评价，使适应性好的染色体有更多的繁殖机会。在算法中也就是以二进制编码的串。并且，在执行遗传算法之前，给出一群染色体，也就是假设解。然后，把这些假设解置于问题的“环境”中，也即在一个适应度函数中来评价。并按适者生存的原则，从中选择出较适应环境的染色体进行复制, 淘汰低适应度的个体，再通过交叉，变异过程产生更适应环境的新一代染色体群。对这个新种群进行下一轮进化，直到最适合环境的值。

2)EP、ES 与 GA 的比较

EP、ES 与 GA 的详细比较情况如表 2-1 所示。

表 2-1　EP、ES 与 GA 的比较

Tab.2-1 The comparison is EP, ES and GA

	主要特点	所用算子	目前应用情况	搜索空间
GA	GA 要将原问题的解空间映射到位串空间中，然后再实行遗传操作，它强调个体基因结构的变化对其适应度的影响。	以选择算子为主要搜索技术，交叉算子和变异算子为辅	应用范围是这三种方法最为广泛的	位串空间
ES	ES 是直接在解空间上进行操作，它强调进化过程中从父体到后代行为的自适应性和多样性。	以变异算子为主要搜索技术，选择算子和交叉算子为辅	一般只适合求解数值优化问题	解空间
EP	EP 直接以问题的可行性作为个体的表现形式，无需再对个体进行编码处理，以及随机扰动因素对个体的影响，因而便于应用。	以变异算子为主要搜索技术，选择算子为辅，不使用交叉算子	目前已用于数据诊断、模式识别和分类及控制系统的设计等	N 维空间

2.3 遗传算法的基本概念

由于遗传算法是由进化论和遗传学机理而产生的搜索算法，所以在这个算法中要用到各种进化和遗传学的概念。这些概念如下：

1)染色体(Chromosome)　生物细胞中含有的一种微小的丝状化合物。这是遗传物质的主要载体，由多个遗传因子－基因组成。

2)个体(Individual)　指染色体带有特征的实体。

3)串(String)　它是个体(Individual)的形式，在算法中为二进制，并且对应于遗传学中的染色体(Chromosome)。

4)基因(Gene)　基因是串中的元素，基因用于表示个体的特征。例如有一个串 S＝

中国知网 https://www.cnki.net

1011，则其中的 1，0，1，1 这 4 个元素分别称为基因。其值称为等位基因(Alletes)。

5)种群(Population)　染色体带有特征的个体的集合称为种群。该集合内个体数称为群体的大小。有时个体的集合也称为个体群。

6)群体大小(Population Size)　在群体中个体的数量称为群体的大小。

7)表现型(Phenotype)　由染色体决定性状的外部表现，或者说，根据遗传子型形成的个体。

8)基因位置(Gene Position)　一个基因在串中的位置称为基因位置，有时也简称基因位。基因位置由串的左向右计算，例如在串 S＝1101 中，0 的基因位置是 3。基因位置对应于遗传学中的地点(Locus)。

9)基因特征值(Gene Feature)　在用串表示整数时，基因的特征值与二进制数的权一致；例如在串 S=1011 中，基因位置 3 中的 1，它的基因特征值为 2；基因位置 1 中的 1，它的基因特征值为 8。

10)串结构空间 S^s　在串中，基因任意组合所构成的串的集合。基因操作是在结构空间中进行的。串结构空间对应于遗传学中的基因型(Genotype)的集合。

11)参数空间 S^r　这是串空间的物理系统中的映射，它对应于遗传学中的表现型(Phenotype)的集合。

12)非线性　它对应遗传学中的异位显性(Epistasis)。

13)适应度(Fitness)　表示某一个体对于环境的适应程度。

14)选择(Selection)　指决定以一定的概率从种群中选择若干个体的操作。一般而言，选择的过程是一种基于适应度的优胜劣汰的过程。

15)复制(Reproduction)　细胞在分裂时，遗传物质 DNA 通过复制而转移到新产生的细胞中，新的细胞就继承了旧细胞的基因。

16)交叉(Crossover)　有性生物在繁殖下一代时两个同源染色体之间通过交叉而重组，亦即在两个染色体的某一相同位置处 DNA 被切断，其前后两串分别交叉组合形成两个新的染色体。这个过程又称基因重组 recombination，俗称“杂交”。

17)变异(Mutation)　在细胞进行复制时可能以很小的概率产生某些复制差错，从而使 DNA 发生某种变异，产生出新的染色体，这些新的染色体表现出新的性状。

18)编码(Coding)　DNA 中遗传信息在一个长链上按一定的模式排列，也即进行了遗传编码。遗传编码可以看作从表现型到遗传子型的映射。

19)解码(Decoding)　从遗传子型到表现型的映射。

2.4 遗传算法的模式定理

模式定理是遗传算法的理论基础，它描述了遗传算法的搜索策略。

1)模式

定义 2.1　设 GA 的个体 $p \in B^l$，记集合 S=$\{0,1,*\}^l$，则称 $\forall s \in$ S 为一个模式(Schemata)，其中，“*”代表通配符，l 表示个体染色体长度。

由以上定义可见，所谓“模式”就是指编码的字符串中具有类似特征的子集。在二进

中国知网　https://www.cnki.net

制编码的串中，模式是基于三个字符集(0,1,*)的字符串，字符“*”是通配符，它表示可以取“1”，又可以取“0”。对于一个模式 s，我们至少可以找到一个和它相匹配的个体 q。例如：s 为 10**101*1010，个体 q 可为：100110101010。

2)模式阶和定义距

定义 2.2　若一个个体 q 的每一位与模式 s 相配，则称 q 是 s 的一个表示。

一个模式代表一个个体的集合，这个集合中的每一个个体都是这个模式的一个表示。

所有的模式并不是以同等机会产生的。有些模式比起其他模式更确定，如模式 011**1 与模式 0*****相比，在相似性方面有明确的表示。有些模式的跨度要比其他的长，如与模式 1*1***相比，1****1 要跨越整个串长更大的部分。为了定量地描述模式，我们引入两个重要参数：模式阶(schema order)和定义距(defining length)。

定义 2.3　一个模式 s 的阶就是指模式中已有明确含意(二进制字符时指 0 或 1)的字符个数，记为 $o(s)$。

例如，模式“0****”的阶为 1，模式“10*0*”的阶为 3。

定义 2.4　一个模式的定义距就是模式中第一个确定位置和最后一个确定位置间的距离，记为 $\delta(s)$。

例如：模式“10***”的定义距为 1，模式“1***0”的定义距为 4。

模式的定义距代表该模式在今后遗传操作(交叉、变异)中被破坏的可能性：模式长度越短，被破坏的可能性越小，长度为 0 的模式最难被破坏。

3)模式定理[20]

定理 2.1(模式定理)　在遗传算子选择、交叉和变异的作用下，具有低阶、短定义距以及平均适应度高于群体平均适应度的模式在子代中得到以指数级增长。

模式定理是遗传算法的理论基础，是由 J.H.Holland 教授创立的，该理论揭示了遗传算法的基本机理。为了很好地理解该定理，下面我们通过一个实例来加深理解。

例：求 max　f(x)= x^2　x $\in\{0,31\}$[23]，则 x 可编码为 5 位二进制数。给定 4 个初始串，然后施加选择、交叉、变异操作，有关的过程由表 2-2 表示。

让我们考察 3 个模式：H_1 =1***、H_2=*10** 和 H_3=1***0 的运行情况。首先来看 H_1 在遗传操作下的变化。在选择阶段，各串按照其适应度在群体适应度中所占的比例进行复制(比例复制法)。观察表 2-2，可以看出，由于串 2 的适应度大，其复制概率高，经过选择被复制成 2 份，而串 3 则丢失了。注意到串 2、4 都是 H_1 的样本，这样通过选择后，H_1 的样本增至为 3。由模式定理，理论上应有 $m\bullet f(H)/f_{avg}$ 个样本，其中 $f(H)$ =(576+361)/2=468.5，而 f_{avg} =293，则 H_1 在选择算子作用下应有 $2\bullet 468.5/293=3.2\approx 3$ 个样本，与实际相符。由于 H_1 的定义距离为 0，交叉操作对 H_1 的样本没有任何影响。而对于变异操作，在变异概率为 P_m=0.001 的情况下，H_1 的 3 个样本遭破坏的概率为 $3\bullet 0.001=0.003$，可以认为不发生变异。事实上，子代中有 3 个 H_1 的样本 11001、11011、10000，H_1 的样本数的确如模式定理所预计的呈指数级增长。

那么模式 H_2、H_3 呢？H_2 的初始样本数为 2，在选择算子作用下，样本数仍为 2。

中国知网　https://www.cnki.net

这与模式定理所预计的 2●320/293=2.18≈2 与实际一致。而模式 H_3 的样本数为 1，预期值为 1●576/293=1.91≈2 与实际值相符。下面来看交叉操作。尽管 H_2 和 H_3 的阶数相同，选择后的样本数也相同，但由于两个模式的定义距不同，在交叉算子作用下的结果也不同。对于 H_2，由模式定理，其预期值应为 m(H_2,t+1)=2.18●(1-1/4)=2.18●0.75=1.64≈2，实际上，最终 H_2 的两个样本都得以保留。而对于 H_3，其预期值为 m(H_3,t+1)=1.97●(1-4/4)=0，但事实上，H_3 有一个样本得以保留(10000)。这似乎与模式定理不相符，但应该强调的是，模式定理给出的只是一个下界，H_3 之所以有一个样本能生存，是因为 H_3 的样本 11000 的配偶 10011 在 H_2 的确定位(位置 1、5)并不互补。尽管如此，我们也可以看出，由于 H_2 具有较短的定义距，其生命力强于 H_3。

表 2-2　遗传算法对模式的处理(串处理)

Tab.2-2 Patterns of genetic algorithm to deal with (string processing)

串号	初始群体	X 值	f(x)	$\frac{f_i}{\sum f}$	期望个数	实际个数	交叉情况	配偶	交叉点	新群体	X 值	f(x)
1	01101	13	169	0.14	0.58	1	0110|1	2	4	01100	12	144
2	11000	24	576	0.49	1.97	2	1100|0	1	4	11001	25	625
3	01000	8	64	0.06	0.22	0	11|000	4	2	11011	27	729
4	10011	19	361	0.31	1.23	1	10|011	3	2	10000	16	256
总和			1170	1.00	4.00	4						1754
平均			293	0.25	1.00	1						439
最大			576	0.49	1.97	2						729

表 2-3　遗传算法对模式的处理(模式处理)

Tab.2-3 Patterns of genetic algorithm to deal with (schemata processing)

		选择前				选择后		下一代	
		串代表	f(H)	期望个数	实际个数	串代表	期望个数	实际个数	串代表
H_1	1****	2,4	469	3.20	3	2,3,4	3.20	3	2,3,4
H_2	*10**	2,3	320	2.18	2	2,3	1.64	2	2,3
H_3	1***0	2	576	1.97	2	2,3	0.0	1	4

以上通过一个实例证实了模式定理的正确性。在遗传算子作用下，低阶、短距、高平均适应度的模式以指数级增长。

2.5 欺骗问题

在遗传算法中，将所有防止评价值高的个体生成从而影响遗传算法正常工作的问题统称为欺骗问题(Deceptive Problem)。遗传算法运行过程具有将高于平均适应度、低阶和短定义距的模式重组成高阶模式的趋势。如果在低阶模式中包含了最优解的话，则遗传算法就可能找出它来。但低阶、高适应度的模式可能没有包含最优串的具体取值，于是遗传就会收敛到一个次优的结果。下面给出有关欺骗性的概念。

定义 2.5 竞争模式 [22]　若模式 H 与 H'中，*的位置完全一致，但任一确定位的编码均不同，则称 H 与 H'互为竞争模式。其中，“*”代表通配符，可取 0 也可取 1。

中国知网 https://www.cnki.net

定义 2.6 欺骗性 [22] 假设 f(X)的最大值对应的 X 集合为 X^*，H 为一包含 X^* 的 m 阶模式。H 的竞争模式为 H’，而且 f(H)>f(H’)，则 f 为 m 阶欺骗。

在上述定义中，当 m=1 时，由于模式中不包含*，自然不存在欺骗性问题。

例如，对于一个 3 位二进制编码的模式，如果 f(111)为最大值时，下列 12 个不等式中任意一个不等式成立，则存在欺骗性问题。

模式阶数为 1 时：f(**1)<f(**0)，f(*1*)<f(*0*)，f(1**)<f(0**)

模式阶数为 2 时：f(*11)<f(*00)，f(1*1)<f(0*0)，f(11*)<f(00*)，f(*11)<f(*10)，f(1*1)<f(0*1)，f(11*)<f(01*)，f(*11)<f(*10)，f(1*1)<f(1*0)，f(11*)<f(10*)

阶数 1 的条件分别与 $\omega_1>0$, $\omega_2>0$, $\omega_3>0$, $\omega_4>0$ 等价。对于阶数 2 的条件，例如 f(1*1)<f(0*1)可化为：$\omega_0-\omega_1-\omega_4+\omega_5<\omega_0-\omega_1+\omega_4-\omega_5$ 即 $\omega_4<\omega_5$。其他条件也可作类似的推导和化简。

2.6 遗传算法的应用概述

进入 90 年代后，遗传算法迎来了兴盛发展时期，无论是理论研究还是应用研究都成了十分热门的课题。尤其是遗传算法的应用研究显得格外活跃，不但它的应用领域扩大，而且利用遗传进行优化和规则学习的能力也显著提高，同时产业应用方面的研究也在摸索之中。此外一些新的理论和方法在应用研究中亦得到了迅速的发展，这些无疑均给遗传算法增添了新的活力。遗传算法提供了一种求解复杂系统问题的通用框架，它不依赖于问题的具体领域，对问题的种类有很强的鲁棒性，所以广泛应用于很多学科。如工程结构优化、计算数学、制造系统、航空航天、交通、计算机科学、通信、电子学、材料科学等。

1)GA 在数值优化上的应用

最优化问题是遗传算法经典应用领域，但采用常规方法对于大规模、多峰态函数、含离散变量等问题的有效解决往往存在许多障碍。对全局变化问题，目前存在确定性和非确定性两类方法。前者以 Brianin 的下降轨线法、Levy 的隧道法和 R.Ge 的填充函数为代表。该类方法虽然收敛快、计算效率高，但算法复杂，求得全局极值的概率不大。遗传算法作为现代最优化的手段，实践证明，它应用于大规模、多峰多态函数、含离散变量等情况下的全局优化问题是合适的，在求解速度和质量上远远超过常规方法。

2)GA 在组合优化中的应用

组合优化(combinational optimization)是遗传算法最大基本的也是最重要的研究和应用领域之一。所谓组合优化是指在离散的、有限的数学结构上，寻找一个满足给定约束条件并使其目标函数值达到最大或最小的解。一般来说，组合优化问题通常带有大量的局部极值点，往往是不可微的、不连续的、多维的、有约束条件的、高度非线性的 NP 完全问题，因此精确地求出组合优化问题的全局最优解一般是不可能的。遗传算法作为一种新型的、模拟生物进化过程的随机化搜索、优化方法，近十几年来在组合优化领域得到了相当广泛的研究和应用，并已在解决诸多典型组合优化问题中显示了良好的性能和效果，例如，求解背包问题，八皇后问题，作业调度问题等。

中国知网 https://www.cnki.net

3)遗传算法在机器学习中的应用

机器学习系统实际上是对人的学习机制的一种抽象和模拟，是一种理想的学习模型。基于符号学习的机器学习系统如监督型学习系统、条件反射学习系统、类比式学习系统、推理学习系统等，只具备一些较初级的学习能力。近年来，由于遗传算法的发展，基于进化机制遗传学习成为一种新的机器学习方法，它将知识表达为另一种符号形式—遗传基因型，通过模拟生物的进化过程，实现专门领域知识的合理增长型学习。

4)遗传算法在并行处理中的应用

遗传算法固有的并行性和大规模并行机的快速发展，促使许多研究者开始研究遗传算法的并行化问题，研究数量更加接近自然界的软件群体将成为可能。遗传算法与并行计算的结合，能把并行机的高速性和遗传算法固有的并行性两者的长处彼此结合起来，从而也促进了并行遗传算法的研究与发展。

5)遗传算法在人工生命中的应用

人工生命是用人工的方法模拟自然生命的特有行为，而基于遗传算法进化模型是研究人工生命的主要基础理论之一，因此二者有着密切的关系。遗传算法、遗传编程和进化计算等是人工生命系统开发的有效工具。一般而言，遗传操作过程和进化计算机制非常适合于描述人工生命系统。

6)遗传算法在图解处理、模式识别中的应用

图像处理和模式识别是计算机视觉中的一个重要研究领域，在图像处理过程中，如扫描、特征提取、图像侵害等不可避免地会产生一些误差，这些误差会影响到图像处理和识别的效果。如何使这些误差最小是使计算机视觉达到实用化的重要要求。遗传算法在图像处理中的优化计算方面是完全能胜任的，目前已在图像校准、图像侵害、几何形状识别、图像压缩、三维重建优化以及图像检索等方面得到了应用。

7)遗传算法在生产调度问题中的应用

生产调度问题在许多情况下所建立起来的数学模型难以精确求解，即使经过一些简化之后可以进行求解，也会因简化太多而使得求解结果与实际相差甚远。因此，目前在现实生产中也主要靠一些经验进行调度。遗传算法已成为解决复杂调度问题的有效工具，在单件生产车间调度、流水线车间调度、生产规划、任务分配等方面遗传算法都得到了有效的应用。

8)遗传算法在计算智能中的地位

计算智能系统是在神经网络、模糊系统、进化计算三个分支发展相对成熟的基础上，通过相互之间的有机融合而形成的新的科学方法，也是智能理论和技术发展的崭新阶段。这些不同的成员方法从表面上看各不相同，但实际上它们是紧密相关、互为补充和促进的。近年来的研究发现：神经网络反映大脑思维的高层次结构；模糊系统模仿低层次的大脑结构；进化系统则与一个生物体种群的进化过程有着许多相似的特征。这些研究方法各自可以在某些特定方面起到特殊的作用，但是也存在一些固有的局限。因此，将这些智能方法有机地融合起来进行研究，就能为建立一种统一的智能系统设计和优化方法提供基础。基于这种考虑，将三者结合起来研究已经成为了一种发展趋势。1994

中国知网 https://www.cnki.net

年起，IEEE 的神经网络、模糊系统、进化计算三大会议合在一起召开，就反映了这种趋势，计算智能作为人工智能新发展的主流地位就从此确定了。

表 2-4 目前遗传算法所涉及的主要应用领域。

表 2-4　遗传算法的主要应用领域

Tab.2-4 The main applications of genetic algorithm

遗传算法应用	自适应控制：导弹控制
	工业优化控制：瓦斯管道控制
	规划设计：生产规划、并行机任务分配、VLSI 布局、网络设计
	模式识别：模糊聚类
	组合优化：TSP 问题、背包问题、车间调度问题、图划分问题
	函数优化：经典应用领域、用于遗传算法自身的研究
	图像处理：特征提取
	信号处理：滤波器设计
	机器学习：知识获取、知识优化
	机器人：机器人智能控制
	人工生命：生命的遗传进化
	遗传编程：遗传程序设计
	神经网络：学习算法的改进

中国知网 https://www.cnki.net

第三章 模拟退火遗传算法

3.1 模拟退火算法

3.1.1 模拟退火算法概述

1982 年，Kirkpatrick [23]等人将退火思想引入组合优化问题领域，提出一种解决大规模组合优化问题，特别是 NP 完全组合优化难题的有效近似算法——模拟退火算法(simulated annealing algorithm)。它是来源于固体退火的原理，先将固体加温至充分高，再将其徐徐冷却的过程。加温时，固体内部粒子随温度上升而变为无序态，内能增大，而徐徐冷却时粒子渐渐趋有序态，在每个温度点上都能达到平衡态，最后在常温时达到基态，内能减为最小。

根据 Metropolis 准则，内部粒子在温度 T 时趋于平衡的概率为 e(-ΔE/(kT))，其中 E 为当温度 T 时的内能，ΔE 为内能改变量，k 为 Boltzmann 常数。用固体退火过程来模拟组合优化问题，先将内能 E 模拟为目标函数值 f，温度 T 演化成控制参数 t，即可得到解组合优化问题的模拟退火算法：由初始解 s 和控制参数初值 t 开始，对当前解重复“产生新解→计算目标函数差→接受或舍弃”的迭代过程，并逐步衰减当前温度 t 值，直至达到结束温度，算法终止时的当前解即为所求近似最优解，这是一种基于蒙特卡罗迭代求解法的启发式随机搜索过程。退火过程由冷却进度表(Cooling Schedule)控制，包括控制参数的温度初值 t 及其衰减因子 Δt、每个 t 值时的迭代次数 L(马尔科夫链)和停止条件 S。

固体退火过程的物理图象和统计性质是模拟退火算法的物理背景；冷却进度表的合理选择是算法应用的前提；而 Metropolis 接受准则使算法跳离局部最优的“陷阱”。

3.1.2 模拟退火算法的基本步骤

模拟退火的基本思想如下：

1) 初始化：初始温度T(充分大)，初始解状态S(是算法迭代的起点)， 每个T值的迭代次数L(马尔科夫链)，减温系数K

2) 对i=1，……，L做3)至6)循环,完成一次马尔科夫链。

3) 通过变异产生新解 S′ 。

4) 计算增量 Δt′=C(S′)-C(S)，其中 C(S)为评价函数 。

5) 若 Δt′<0 则接受 S′作为新的当前解，否则以概率 exp(-Δt′/T)接受 S′作为新的当前解.。

6) 如果满足终止条件则输出当前解作为最优解，结束程序。 否则转到 7)。

7) T 逐渐减少(T=T*K)，且 T>0，然后转 2)。

固体退火是先将固体加热至融化，然后徐徐冷却使之凝固成规整晶体的热力学过程。从统计物理学的观点看，随着温度的降低，物质的能量将逐渐趋近于一个较低的状态，并最终达到某种平衡。

中国知网 https://www.cnki.net

固体温度参数 T，反复进行状态转移过程，新状态的接受概率 P(x)服从 Gibbs 分布：

$$p(x)=\frac{1}{z}\exp(-\frac{E(x)}{T}) \tag{3-1}$$

式中，z 为概率正则化系数，E(x)为状态 x 的能量。由上式可知，随着温度参数的减小，接受概率也随着减小，即能量函数增大的可能性也逐渐减小，最后系统会收敛于某一能量最小的状态。显然模拟这样的固体退火过程，应用于组合优化中是可行的。

设组合优化问题的一个解 i 及其目标函数分别与固体的微观状态 i 及其能量 Ei 等价。令随着算法进程递减其值的控制参数 t 担当固体退火过程中的温度 T 的角色，则对于控制参数 t 的每一个取值，算法持续进行“产生新解→判断→接受/舍弃”的迭代过程就对应于固体在某一恒定温度下趋于热平衡的过程。从统计物理学获得的 Metropolis [56]接受准则应用于确定从当前解 i 到新解 j 转移的概率 P_k：

$$P_k(i\Rightarrow j)=\begin{cases}1, f(i)\le f(j)\\ \exp(-\frac{f(i)-f(j)}{t}), otherwise\end{cases} \tag{3-2}$$

上式(3-2)中，f(i)为解 i 的适应度。开始时让 t 取较大的值，在进行足够的状态转移后，缓慢减小 t 的值，如此反复，直至满足某个停止准则时算法终止。因此，模拟退火算法可视为递减控制参数时 Metropolis 算法的迭代。

模拟退火算法新解的产生和接受可分为如下四个步骤：

第一步是由一个新解产生函数从当前解产生一个位于解空间的新解；为了便于后续的计算和接受，减少算法的耗时，通常采用由当前解经过简单地变换即可产生新解的方法，如对构成新解的部分或全部元素进行互换、置换等，注意到产生新解的变换方法决定了当前新解的邻域结构，所以对冷却进度表的选取也有一定的影响。

第二步是计算新解与原先解所对应的目标函数差(适度度差)。因为目标函数差仅由变换部分产生，所以目标函数差的计算最好按增量计算，这样也可以减少算法的耗时。事实也表明，对大多数应用而言，这是计算目标函数差的最快最便捷方法。

第三步是判断新解是否被接受,判断的依据是一个接受准则，最常用的接受准则是 Metropo1is 准则: 若 Δt′<0(新解的适应度大于原先解)，则接受 S′作为新的当前解 S，否则以概率 exp(-Δt′/T)接受 S′作为新的当前解 S。

第四步是当新解被确定接受时，用新解代替当前解，这只需将当前解中对应于产生新解时的变换部分予以实现，同时修正目标函数值即可。此时，当前解实现了一次迭代(马尔科夫链)。可在此基础上开始下一轮试验。如果当新解被判定为舍弃时，则在原当前解的基础上继续下一轮试验。

模拟退火算法与初始值无关，算法求得的解与初始解状态 S(算法迭代的起点值)无关；模拟退火算法具有渐近收敛性，已经在理论上被证明是一种以概率 1 收敛于全局最优解的全局优化算法，模拟退火算法具有并行性。

中国知网 https://www.cnki.net

3.2 基本遗传算法

3.2.1 基本遗传算法步骤

遗传算法[24]类似于自然进化，通过作用于染色体上的基因寻找好的染色体来求解问题。与自然界相似，遗传算法对求解问题的本身一无所知，它所需要的仅仅是对算法产生的每个染色体进行评价，并基于适应值来选择染色体，使适应性好的染色体有更多的繁殖机会。在遗传算法中，通过随机方式产生若干个所求解问题的数字编码，即染色体，形成初始种群；通过适应度函数给每个个体一个数值评价，淘汰低适应度的个体，选择高适应度的个体参加遗传操作，经过遗传操作后的个体集合形成下一代新的种群。再对这个新种群进行下一轮进化。这就是遗传算法的基本原理。遗传算法的主要步骤如下：

1)随机产生一个由确定长度的特征串组成的初始群体。

2)对串群体迭代地执行步骤(1)和(2)，直到满足停止准则：

(1)计算群体中每个个体的适应值。

(2)应用复制、杂交和变异算子产生下一代群体。

3)把在任一代中出现的最好的个体串指定为遗传算法的执行结果。这个结果可以表示问题的一个解(或近似解)。

基本遗传算法的流程图如图 3-1：其中 GEN 是当前代数，M 为每代种群中最大个体数。

3.2.2 遗传算法染色体编码

运用遗传算法解决一个特殊问题时，首先要找出一种适合的表示方法来表示该问题的可行解，也就是编码。一般地，可行解是一个二进制串，称为染色体。这个串的长度取决于要求的精度。有一些情况，二进制串不适合表示它们的解，一些研究者已经研究出其它方法来表示它们的解，比如有序列表、嵌入式列表、可变因素列表等。

Holland 提出的遗传算法是采用二进制编码[25]来表现个体的遗传基因型的，它使用的编码符号集由二进制符号 0 和 1 组成的，因此实际的遗传基因型是一个二进制符号串，其优点在于编码、解码操作简单，交叉、变异等遗传操作便于实现，而且便于利用模式定理进行理论分析等；其缺点在于，不便于反映所求问题的特定知识，如对于一些连续函数的优化问题等，也由于遗传算法的随机特性而使得其局部搜索能力较差，对于一些多维、高精度要求的连续函数优化，二进制编码存在着连续函数离散化时的映射误差，个体编码串较短时，可能达不到精度要求；而个体串的长度较长时，虽然能提高精度，但却会使算法的搜索空间急剧扩大。如果个体编码串特别长时，会造成遗传算法的性能降低。后来许多学者对遗传算法的编码方法进行了多种改进，例如，为提高遗传算法局部搜索能力，提出了格雷码[26](Grey Code)编码；为改善遗传算法的计算复杂性、提高运算效率，提出了浮点数编码；为便于利用求解问题的专门知识，便于相关近似算法之间的使用，提出了符号编码法；此外还有多参数级联编码和交叉编码方法，近年来，随着生物计算理论研究的兴起，有人提出 DNA 编码法，在模糊控制器优化的应用中取得很好的效果。

中国知网 https://www.cnki.net

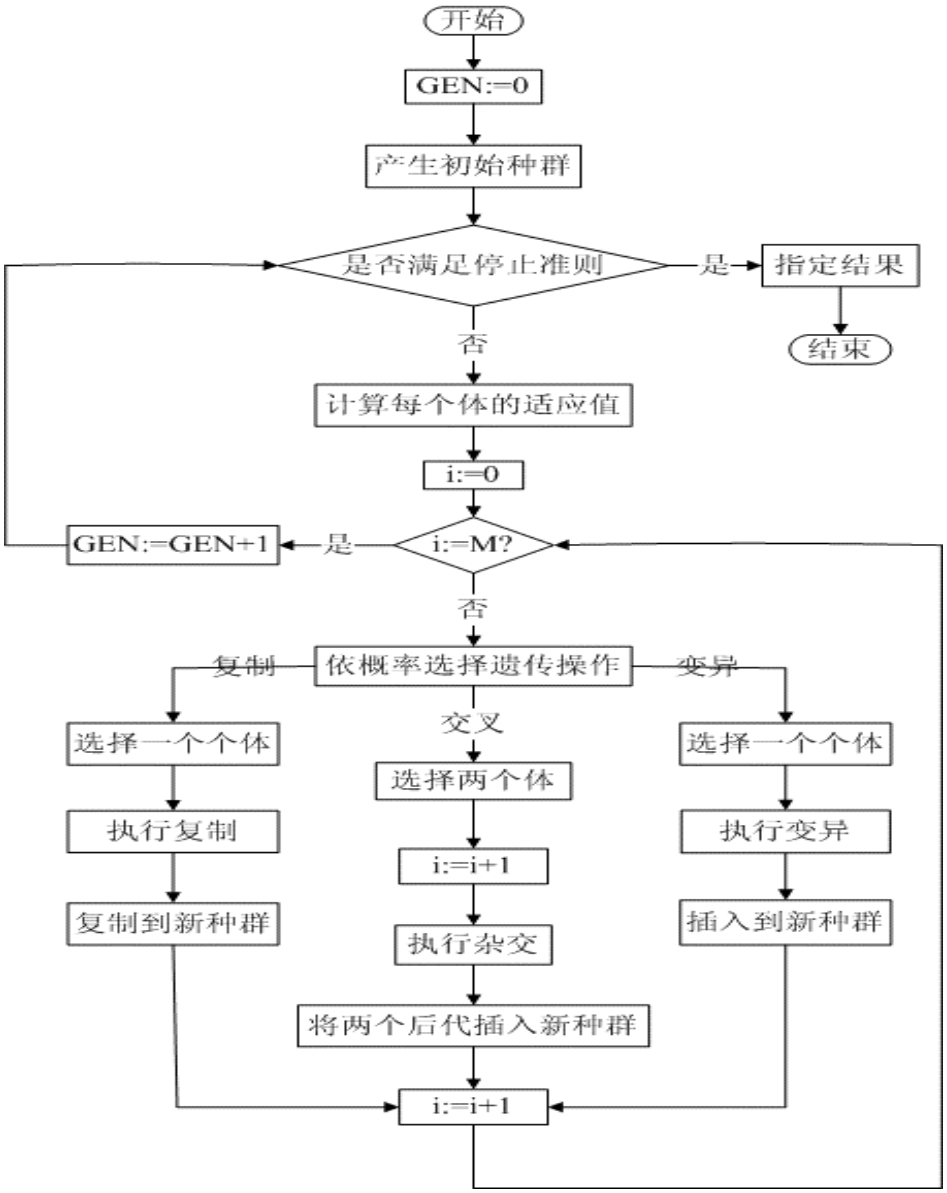

图 3-1 基本遗传算法的流程图

Fig.3-1 The Process Figure of the basic genetic algorithm

理论上而言，编码应该适合要解决的问题，而不是简单的描述问题。Balakrishman[27]等较全面地讨论了不同编码方法的一组特性，针对一类特别的应用，为设计和选择编码方法提供了指南，主要有以下九个特性：

(1)完全性(Completeness)　原则上，分布在所有问题域的解都可能被构造出来。

(2)封闭性(Closure)　每个基因编码对应一个可接受的个体，封闭性保证系统从不产生无效的个体。

(3)紧致性(Compactness)　若两种基因编码 g1 和 g2 都被解码成相同的个体，若 g1 比 g2 占的空间少，就认为 g1 比 g2 紧致。

(4)可扩展性(Scalability)　对于具体的问题，编码的大小确定了解码的时间，两者存在一定的函数关系，若增加一种表现型，作为基因型的编码大小也要作相应的增加。

(5)可重性(Multiplicity)　多个基因型解码成一个表现型，即从基因型到相应的表现型空间是多对一的关系，这是基因的可重性。若相同的基因型被解码成不同的表现型，

中国知网 https://www.cnki.net

这是表现型的多重性。

(6)个体可塑性(Flexibility) 决定表现型与相应给定基因型是受环境影响的。

(7)模块性(Modundancy) 若表现型的构成中有多个重复的结构，在基因型编码中这种重复是应当避免的。

(8)冗余性(Redundancy) 冗余性能够提高可靠性和鲁棒性(Robustness)。

(9)复杂性(Complexity)包括基因型的结构复杂性，解码复杂性，计算时空复杂性(基因解码、适应值、再生等)。

3.2.3 适应度函数

在每一代产生的过程中，用一些与最优化问题的目标函数相关的适应度函数(fitness function)，来评价这些染色体。用基于评价值的遗传算子来选择染色体。遗传算法整个过程都是利用这种原始评价值来进行搜索，所以适应度函数的选取至关重要，直接影响到遗传算法的收敛速度以及能否找到最优解。遗传算法利用原始评价值使种群中具有高适应度染色体的个体比低适应度多需要很长时间，所以遗传算法执行时需要很灵活地缩放适应度函数，即适应度的尺度变换(fitness scaling)。

适应度函数[28]基本上有以下三种：

1)直接以待求解的目标函数的转化为适应度函数，即：

若目标函数为最大化问题 Fit(f(x))=f(x)

若目标函数为最小问题 Fit(f(x))=-f(x)

这种适应度函数简单直观，但存在两个问题，其一是可能不满足常用的轮盘赌选择中概率非负的要求；其二是某些待求解的函数在函数值分布上相差很大，由此得到的平均适应度可能不利用于体现种群的平均性能，影响算法的性能。

2)若目标函数为最小问题，则

$$fit(f(x))=\begin{cases} c_{\max}-f(x), f(x)<c_{\max} \\ 0,\text{其它} \end{cases} \tag{3-3}$$

式中 $c_{\max}$ 为 f(x)的最大值估计。

若目标函数为最大问题，则

$$fit(f(x))=\begin{cases} f(x)-c_{\min}, f(x)>c_{\max} \\ 0,\text{其它} \end{cases} \tag{3-4}$$

这种方法是对第一种方法的改进，可称为“界限构造法”，但有时存在界限值预先估计困难、不可能精确的问题。

3)若目标函数为最小问题

$$fit(f(x))=\frac{1}{1+c+f(x)}, c\geq 0, c+f(x)\geq 0 \tag{3-5}$$

若目标函数为最大问题

$$fit(f(x))=\frac{1}{1+c-f(x)}, c\geq 0, c-f(x)\geq 0 \tag{3-6}$$

中国知网 https://www.cnki.net

这种方法与第二种方法类似，c 为目标函数界限的保守估计值。

3.2.4 遗传算子

1)选择算子(Selection Operator)

双亲选择是从种群中选择优胜的个体直接遗传到下一代或通过配对交叉产生新的个体再遗传到下一代。双亲选择[29]是建立在群体中个体的适应度评估基础上的，目前常用的选择算子及特点见表 3-1。

表 3-1　选择算子

Tab.3-1 Selection Operator

序号	名称	特点	研究者
1	轮盘赌选择(回放式随机采样)	选择误差较大	DeJong,Brindle
2	无回放式随机采样	降低选择误差，复制数(f/(f+1))，操作不便	DeJong,Brindle
3	确定采样	选择误差更小，操作简易	Brindle
4	柔性分段式选择	有效防止基因缺失但需要选择有关参数	Yun
5	自适应柔性分段式动态群体采样	群体自适应变化，提高搜索效率	Yun
6	无放回式余数随机采样	群体自适应变化，提高搜索效率	DeJong,Brindle
7	均匀排序	与适应度的大小差异程序正负无关	Back
8	稳态选择	保留父代中的一些高适应度的串	Syswerda
9	随机比赛		Brindle
10	选择评价		Whitley
11	最优串选择	全局收敛，提高搜索效率	DeJong.Back
12	最优串保留	保证全局收敛	Yun
13	适应度线性尺度变换	简单，可消除遗传早期的超级串现象	Bagley
14	适应度指数尺度变换		Gillies
15	适应度自适应线性尺度变换	符合遗传机理	Yun

2)交叉算子(Crossover Operator)

在自然界生物进化过程中起核心作用的是生物遗传基因的重组(加上变异)。同样，遗传算法中起核心作用的是遗传操作的交叉算子[30]。所谓交叉是指把两个父代个体的部分结构加以替换重组而生成新个体的操作。通过交叉，遗传算法的搜索能力得以飞跃提高。目前典型的交叉算子及特点如表 3-1 所示。

本节以字符串编码为前提介绍几种基本交叉方法。

(1)单点交叉(one-point crossover)

一点交叉又叫简单交叉。具体操作是：在个体串中随机设定一个交叉点，实行交叉时，该点前或后的两个个体的部分结构进行互换，并生成两个新个体。下面给出了一点交叉的例子。

个体 A　1101 | 111　　交叉后新个体 A’　1101000

个体 B　1011 | 000　　交叉后新个人 B’　1011111

中国知网　https://www.cnki.net

其中，交叉点设置在第 4 和第 5 个基因座之间。交叉时，该交叉点后的两个个体的部分码串互相交换。这样，个体 A 的第一到第四个基因与个体 B 第五到第七个基因组成一个新的个体 A’。同样，可得到新个体 B’。交叉点是随机设定的，当染色体长为 n 时，可能有 n-1 个交叉点设置，所以，一点交叉可能实现 n-1 个不同的交叉结果。

(2)二点交叉(two－point crossover)

二点交叉的操作与一点交叉类似，只是设置 2 个交叉点(依然是随机设定)。一个二点交叉的例子表示如下：

个体 A　10 | 110 | 11　　交叉后新个体 A’　1001011

个体 B　00 | 010 | 00　　交叉后新个体 B’　0011000

由此可见，两个交叉点分别设定在第二基因座和第三基因座以及第五基因座和第六基因座之间。A，B 两个体在这两个交叉点之间的码串相互交换，分别生成新个体 A’和 B’。对于二点交叉而言，若染色体长为 n，则可能有(n-2)(n-3)种交叉点的设置。

(3)多点交叉(nulti－point crossover)

多点交叉是前述两种交叉的推广，有时又被称为广义交叉(generalized crossover)。若用参数 cp 来表示交叉点数，则当 cp=1 时，广义交叉就等效于一点交叉。当 cp 为偶数时，根据交叉互换规律，染色体可以当作基因环来处理。当 cp 为奇数时，它可以等效为偶数点交叉。此时，可假定在码串的头部(即基因座 0)有一个交叉点。一般来讲，多点交叉较少采用，因为它影响遗传算法的在线和离线性能。

(4)均匀交叉

单点和多点交叉的定义使得个体在交叉点处分成片段。均匀交叉更加广义化，将每个点都作为潜在的交叉点。随机地产生与个体等长的 0－1 掩码，掩码中的片段表明了哪个父个体向子个体提供变量值。

考虑如下两个 11 位变量的个体：

父个体 1　　0 1 1 1 0 0 1 1 0 1 0

父个体 2　　1 0 1 0 1 1 0 0 1 0 1

掩码样本(1 表示父个体 1 提供变量值，0 表示父个体 2 提供变量值)：

样本 1　　0 1 1 0 0 0 1 1 0 1 0

样本 2　　1 0 0 1 1 1 0 0 1 0 1

交叉后两个新个体为：

子个体 1　　1 1 1 0 1 1 1 1 1 1 1

子个体 2　　0 0 1 1 0 0 0 0 0 0 0

均匀交叉类似于多点交叉，可以减少二进制编码长度与给定参数特殊编码之间的偏差。它的算法与离散重组是等价的。

表 3-2 列出了多种交叉算子及特点。

中国知网　https://www.cnki.net

表 3-2　交叉算子

Tab.3-2 Crossover Operator

序号	名称	特点	研究者	适用编码
1	单点交叉	基于 GA 的成员	Holland,DeJong,Goldberg	符号
2	双点交叉	使用较多	Cavicchio,Booker	符号
3	均匀交叉	每一位以相同的概率交叉	Syswerda,whitely,Yun	符号
4	多点交叉	交换点大于 2	DeJong,Spears	符号
5	部分匹配(PMX)		Goldberg	序号
6	序号交叉(OX)		Davis	序号
7	圆交叉(CX)		Smith	序号
8	基于位置交叉		Syswerda	序号
9	算术交叉		Michalewicz	实数
10	启发式交叉	应用领域知识	Grffenstette	序号

3)变异算子(Mutation Operator)

变异算子[31]的基本内容是对群体的个体串的某些基因座上的基因值变动。基于字符集{0,1}的二值码串而言，变异操作就是把某些基因座上的基因值取反，即 1→0 或 0→1。一般来说，变异算子操作的基本步骤如下：

(1)在群体中所有个体的码串范围内随机地确定基因座。

(2)以事先设定的变异概率 P_m 来对这些基因座的基因值进行变异。

遗传算法引入变异的目的有两个：一是使遗传算法具有局部的随机搜索能力。当遗传算法通过交叉算子已接近最优解领域时，利用变异算子的这种局部随机搜索能力可以加速向最优解收敛。显然，此种情况下的变异概率应取较小值，否则接近最优解的积木块会因变异而遭到破坏。二是使遗传算法可维持群体多样性，以防止出现未成熟收敛现象。此时收敛概率应取较大值。目前常用的变异算子及特点见表 3-3。

表 3-3 变异算子

Tab.3-3 Mutation Operator

序号	名称	特点	研究者	适用编码
1	常规位突变	基本 GA 的成员	DeJong	符号
2	有效基因突变	避免有效基因缺失	Yun	符号
3	自适应有效基因突变	最低有效基因个数自适应变换	Yun	符号
4	概率自调整突变	由两个串的相似性确定突变概率	Whitley	符号
5	均匀突变	每一个实数元素以相同的概率在域内变动	Michalewicz	实数
6	非均匀突变	使整个矢量在解空间轻微变动	Michalewicz	实数
7	三次高斯近似突变		Bosworth,Foo,zeigler	实数

中国知网 https://www.cnki.net

3.3 模拟退火遗传算法

模拟退火遗传算法[32](Simulated Annealing Genetic Algorithms，SAGA)是将模拟退火算法与遗传算法相结合的一种混合算法。目前国内外已有一些将模拟退火算法与遗传算法相结合的例子。

目前常见的 GA 与 SA 相结合有两种方式：在 GA 中引入退火思想，形成动态 GA；将 SA 作为局部搜索算子，利用 SA 的性能来改善 GA 的局部搜索能力。Lin 等人把 GA 与 SA 进行综合，构成模拟退火遗传算法，在解决几种 NPC 问题中显示了良好的性能和效果。D.Brown，C.Huntley 等提出了 SAGA 的策略[33]，先利用 GA 去演化一组解，然后在每一代中使用 SA 对演化后的解进行局部搜索以改进 GA 的性能。Bellgard 等人用 GA 和 SA 合成为遗传 Baltzman 机，用于优化 Baltzman 机的权重[34]。1990 年 Lawrence 出版了其专著<<Genetic Algorithms and Simulated Annealing>>，本专著中详细论述了 GA 与 SA 结合思想及实现方式 。D.Sirag 和 P.Weisser 将退火进程引入 GA 循环过程中[35]，提出了热动力算子。D.Adler 则在文献中提出了将 GA 与 SA 结合的更一般的方法[36]。通过调整相应的参数，可以使算法侧重于 GA 或 SA，甚至可以使它成为纯粹的 GA 或 SA。

3.3.1 国外研究情况

国外较多采用文献[37][38]的结合方法，利用模拟退火的特性来改变遗传算法的性能。首先通过 GA 来进化一个随机种群，然后再通过 SA 来对整个种群进一步优化。算法流程如下：

Begin

1)初始化参数：如种群数目 Pnum，退火速率 k，世代数等。

2)初始种群：采用随机的方式产生满足要求的初始解，当前代数 gen=1。

3)计算适应度：对初始种群中各个体进行评价，计算适应度。

4)判断算法收敛条件是否满足？若是，转到步骤 8)；否则转到步骤 5)。

5)产生新种群

(1)选择双亲：先计算各个体的选择概率，根据轮盘赌方法在当前种群中选择两个体作为双亲。

(2)交配：对选择好的双亲运用交叉算子产生子个体。

(3)变异：对产生的子个体以很小的概率运用变异操作。

(4)判断子个体数目是否达到 Pnum，若是，转到步骤 6)；否则回到步骤(1);

6)对所有新产生的子个体进行模拟退火处理，形成新种群作为下一代种群。

7)计算新产生的种群中各个体的适应度，当前代数 gen=gen+1，转到步骤 4)。

8)输出模拟退火遗传算法的仿真结果。

End

从上述的结合方式可以看出遗传算法的搜索性能确实提高了很多，模拟退火算法的局部搜索能力确实得到了发挥，但是对整个种群进行退火处理，当种群规模过

中国知网 https://www.cnki.net

大时，算法运行的时间是无法忍受的，而且模拟退火算法没有能够很好地利用遗传算法得到的全局信息。

3.3.2 国内研究情况

国内通常采用文献[39][40]中的结合方法，先取一些随机解构成种群，再对每个个体进行退火处理。文献[41][42]中对模拟退火算法作了改进，但模拟退火算法与遗传算法的结合方式还是采用文献[39][40]的方法。由模拟退火接受的新解构成新的种群，再用 GA 的选择、交叉、变异进行处理。算法流程如下：

Begin

1)初始化参数：如种群数目 Pnum，退火速率 k，世代数等。

2)初始种群：采用随机的方式产生满足要求的初始解，当前代数 gen=1。

3)模拟退火处理：对上述产生的初始种群中每个体进行退火处理。

4)种群替换：用模拟退火后的每个体构成一个新种群，用这个新种群来替换原有的初始种群，作为遗传算法真正的初始种群。

5)计算适应度：对初始种群中各个体进行评价，计算适应度。

6)判断算法收敛条件是否满足？若是，转到步骤 9)；否则转到步骤 7)。

7)产生新种群

(1)选择双亲：先计算各个体的选择概率，根据轮盘赌方法在当前种群中选择两个体作为双亲。

(2)交配：对选择好的双亲运用交叉算子产生子个体。

(3)变异：对产生的子个体以很小的概率运用变异操作。

(4)判断子个体数目是否达到 Pnum，若是，转到步骤 8)；否则回到步骤(1);

8)计算新产生的种群中各个体的适应度，当前代数 gen=gen+1，转到步骤 6)。

9)输出模拟退火遗传算法的仿真结果。

End

从上述流程可以看出，先用模拟退火算法对随机产生的初始种群进行处理，使得遗传算法的初始种群变得非常优化。而且模拟退火算法只在开始时对种群所有个体进行处理，即使种群规模过大，也不会占用太长时间。但是，模拟退火算法本身是一个局部搜索算法，一开始就使用它来处理种群，可能会使初始种群中的个体为局部最优解，遗传算法再从这样的种群中进行双亲选择，很容易陷入局部最优解，出现“早熟”现象。

中国知网 https://www.cnki.net

第四章 求解 TSP 问题的 GCBSAGA 算法

巡回旅行商问题（TSP）是最典型的NP难题，它具有非常广泛的实际应用价值。遗传算法（GA）是解决这类问题的有效方法之一。遗传算法具有很强的全局搜索能力，可以快速地从解空间中搜索出全局较优解，而不会陷入局部最优解的快速下降陷阱。但是遗传算法的局部搜索能力比较差，导致单纯的遗传算法比较浪费时间，在进化后期搜索能力非常低。在实际问题应用中，容易产生“早熟”的现象。采用什么样的算子，既能保留优良个体，又能维持群体多样性，一直是遗传算法长期难以解决的问题。

模拟退火算法(SA)也是解决TSP问题的有效方法。模拟退火算法具有摆脱局部较优解的能力，最终能够找到全局最优解。但是，由于模拟退火算法对全体解空间不了解，所以不能很快落入最有希望的搜索区域，使得模拟退火算法占用大量时间，运算效率不高。

TSP 问题的解是一种特殊的序列，一般的交叉算子在该问题的求解效果方面并不理想，本文针对此问题提出了贪心的 3PM 交叉算子，同时又引入退火选择方法，并将改进后的遗传算法与改进后的模拟退火算法相结合，形成一种基于贪心 3PM 交叉算子的模拟退火遗传算法(GCBSAGA)。该算法高温时运行遗传算法，使得遗传算法在前期发挥着全局搜索的强大功能,很容易收敛到全局较优解；低温时运行模拟退火算法，来处理遗传算法前期的全局较优解，充分利用模拟退火算法后期局部搜索的强大功能，最终收敛到全局最优解。经过国际公认的 TSPLIB 库提供的实验数据进行验证，GCBSAGA 在实例 eil76、eil101、pr144、st70 均找到了比 TSPLIB 提供的最优路径更优的解。

4.1 巡回旅行商问题

本章以遗传算法在组合优化领域中的经典问题TSP的求解为例来说明其应用。巡回旅行商问题[43](Traveling Salesman Problem,TSP)，也称为货郎担问题，是一个较古老的问题。最早可以追溯到1759年Euler提出的骑士旅行问题。1948年，由美国兰德公司推动，TSP成为近代组合优化领域的一个典型难题。应该说，TSP是一个具有广泛的应用背景和重要理论价值的组合优化问题，它已经被证明属于NP难题。TSP在大规模集成电路(VLSI)设计[44]、网络路由、车辆选路等领域有着广泛应用，是NP完全问题中的最为典型的问题。解决它对于解决所有NP完全问题具有重要的理论意义，所以长期以来一直吸引着众多领域的研究人员对其进行研究和算法改进。

TSP问题可以这样描述[45]：假设有一个旅行商人要拜访n个城市，他必须选择所有要走的路径，路经的限制是每个城市只能拜访一次，而且最后要回到原来出发的城市。路径的选择目标是要求得的路径路程为所有路径之中的最小值。TSP问题是一种很简单的问题，一个最容易想到的方法是利用排列组合的方法把所有的路径都计算出来，并逐一比较，选出最小的路径。虽然该方法在理论上是可行的，但路径的个数与城市的个数成指数增长，当城市个数较大时，该方法的求解时间是难以忍受的，甚至是不可能完成的。以每秒1亿次的计算速度来估算，如果TSP问题包含20个城市时，求解时间长达350

中国知网 https://www.cnki.net

年；如果要处理30个城市，则求解时间更长达1+10e16年。如此长的时间，在实际中完成是难以想象的。

用图语言来描述 TSP，给出一个图 G=(V，E)，每边 e∈E 上有非负权值ω(e)，寻找 G 的 Hamilton 圈 C，使得 C 的总权 W(C)= $\sum_{e\in E(C)}\omega(e)$ 最小。

TSP 搜索空间随着城市数 n 的增加而增大，所有的旅程路线组合数为(n-1)!/2。5 个城市的情形对应 120/10=12 条路线，10 个城市的情形对应 3628 800/20=181 440 条路线地，100 个城市的情形则对应有4.6663×10^{155}条路线。在如此庞大的搜索空间中寻求最优解，对于常规方法和现有的计算工具而言，存在着诸多的计算困难。借助遗传算法的搜索能力解决 TSP 问题，是很自然的想法。但如果将一条旅程路线表示为一个 n 城市的排列，基于二进制编码的交叉和变异操作就不能适用，所以需要重新设计遗传操作，以适应这类遗传基因表示问题。

下面我们结合 9 个城市的 TSP，讨论几种遗传算法交叉算子的应用方法。

4.1.1 顺序表示与交叉

Grefenstette[46]等人针对 TSP 提出了基于顺序表示(ordinal representation)的遗传基因编码方法。顺序表示是指将所有城市依次排列构成一个顺序表(order list)，对于一条旅程，可以依照旅行经过顺序处理每个城市，每个城市在顺序表中的顺序就是一个遗传因子的表示，每次处理完一个城市，从顺序表中去掉该城市。处理完所有城市后，将每个城市的遗传因子表示连接起来，即成为一条旅程的基因表示(染色体编码)。例如，顺序表 C=(1,2,3,4,5,6,7,8,9)，一条旅程为 1－2－4－3－8－5－9－6－7。按照这种编码方法，这条旅程的编码为表 L=(1 1 2 1 4 1 3 1 1)。

由于采用这种顺序表示技术，可以采用基本遗传算法的交叉操作，例如，单点交叉的情形，父个体 1 和父个体 2 分别为：

P1：(1 1 2 1 | 4 1 3 1 1)

P2：(5 1 5 5 | 5 3 3 2 1)

它们代表的旅程分别为：

1－2－4－3－8－5－9－6－7

5－1－7－8－9－4－6－3－2

两个个体在交叉点处进行基因重组，生成子个体 1 和子个体 2，分别为

O1：(1 1 2 1 5 3 3 2 1)

O2：(5 1 5 5 4 1 3 1 1)

它们代表旅程分别为：

1－2－4－3－9－7－8－6－5

5－1－7－8－6－2－9－3－4

从上述单点交叉来看，交叉点右侧部分的旅程发生了随机变化，但交叉点左侧部分的旅程未发生改变，由于顺序表示和单点交叉存在这个缺点，这种方法的适用性存在一

中国知网 https://www.cnki.net

定的问题。

4.1.2 路径表示与交叉

路径表示(path representation)是表示旅程对应的基因编码的最自然、最简单的表示方法。例如，旅程 5－1－7－8－9－4－6－2－3 可以直接表示为(5 1 7 8 9 4 6 2 3)，基于路径表示的编码方法，要求一个个体(即一条旅程)的染色体编码中不允许有重复的基因码，也就是说要满足任一个城市必须而且只能访问一次的约束。这样，基本遗传算法的交叉操作生成的个体一般不能满足这一约束条件。为此，人们提出了一个称为重排操作的新操作来处理这类表示问题，它包括三种操作：部分匹配交叉(Partially Matched Crossover,PMX)、郭涛交叉(GuoTao Crossover,GTX)、循环交叉(Cycle Crossover,CX)。

1)部分匹配交叉　1985 年，Goldberg[47]等针对 TSP 提出了基于路径表示的部分匹配交叉(PMX)，操作要求随机选取两个交叉点，以便确定一个匹配段，根据两个父个体中两个交叉点之间的中间段给出的映射关系生成两子个体。

例如，对下面两个父个体的表示，随机地选择两个交叉点“|”。

P1：(1 2 3 | 4 5 6 7 | 8 9)

P2：(4 5 2 | 1 8 7 6 | 9 3)

首先，两个交叉点之间的中间段交换，得到：

O1：(x x x | 1 8 7 6 | x x)

O2：(x x x | 4 5 6 7 | x x)

其中 x 表示暂未定义码(本节下同)，得到中间段的映射关系，有：

1↔4，8↔5，7↔6，6↔7

然后，对于子体 1、子个体 2 中 x 部分，分别保留从其父个体中继承未选定的城市码 2，3，9，得到：

O1：(x 2 3| 1 8 7 6 | x 9)

O2：(x x 2 | 4 5 6 7 | 9 3)

最后，根据中间段的映射关系，对于上面子个体 1 的第一个 x，使用最初父码 1，由 1↔4 交换得到第一个 x，类似地子个体 2 的第二个体 x，使用最初父码 8，由 8↔5 交换得到子个体 1 的第二个 x 为 5。如果映射关系中存在传递关系，即备选交换有多个码，则选择此前未确定的一个码作为交换。类似地进行操作，最终得到的子个体为：

O1：(4 2 3 | 1 8 7 6 | 5 9)

O2：(1 8 2 | 4 5 6 7 | 9 3)

2) 郭涛交叉　郭涛交叉算子(GTX)[48][49]是郭涛提出的一种基于子空间搜索的群体随机搜索算法，已经被证明是一种高效的遗传算子。创新之处在于遗传算子实施的倒位操作，通过该操作，可以有效地增加种群的多样性，扩大搜索区域，防止过早地产生局部收敛，出现“早熟”现象，且最终能找出满足条件的最优解。

在一父体 P1 中随机选取一个城市 C，另取一个父体 P2，在 P2 中指定 C 的下一个城市为 C’。对 P1 中 C 的下一个城市与 C’间的城市实施倒位操作，若 P1 中 C’是与 C 相邻的城市，则不进行倒位操作。

中国知网 https://www.cnki.net

例如，对下面两个父个体的表示。

P1：(1 2 3 4 5 6 7 8 9)

P2：(4 5 2 1 8 7 6 9 3)

首先，从 P1 中随机选择一个城市为 1，再从 P2 中找到城市 1 的下一个城市为 8，然后回到 P1，将城市 1 和城市 8 之间的所有城市倒位处理，包括这两个这两个城市。得到子个体为：

O1：(8 7 6 5 4 3 2 1 9)

3)循环交叉　Oliver[50]等人针对 TSP 提出了循环交叉(CX)操作。CX 操作中子个体中的城市码顺序由任一父个体产生。

例如，下面为两个父个体：

P1：(1 2 3 4 5 6 7 8 9)

P2：(4 1 2 8 7 6 9 3 5)

先从父个体 1 中取第一个城市码，生成子个体 1：

O1：(1 x x x x x x x x)

子个体的所有城市从任一父个体的相同位置取出，由于个体 2 中与父个体 1 的第 1 个城市码 1 对应的城市码为 4，因此决定子个体 1 的第 4 个城市码为 4：

O1：(1 x x 4 x x x x x)

接下来，选出的城市码为 4 对应父个体 2 的城市码为 8，因此，确定子个体 1 的第 8 个城市码：

O1：(1 x x 4 x x x 8 x)

接照这样的规则，依次确定子个体的 1 城市码，直到又再次选择城市 1，称为一个循环，获得：

O1：(1 2 3 4 x x x 8 x)

最后，将子个体 1 中未定义码 x 用父个体 2 中的对应城市码，完成子个体 1 的产生过程。有：

O1：(1 2 3 4 7 6 9 8 5)

同样，可以产生子个体 2 为：

O2：(4 1 2 8 5 6 7 3 9)

4.2 求解 TSP 问题的 GCBSAGA 算法

本文提出的基于3PM(Parents Mating)交叉算子的模拟退火遗传算法（Greedy 3PM Crossover operator Based Simulated Annealing Genetic Algorithms，GCBSAGA）不同于目前已有的模拟退火遗传算法算法。首先，它对遗传算法进行改进，使得全局搜索效率更高。然后，将一般的模拟退火算法进行改进，使得模拟退火算法的局部搜索能力更强。最后，将改进的模拟退火算法嵌入到改进的遗传算法中。其过程是随机产生一组初始群体，通过选择、交叉、变异等改进的遗传算子来产生一组新的个体，这样不断循环，直到产生的新群体的最优个体比父代差，之后选择最优个体，独立的对其进行模拟退火操

中国知网 https://www.cnki.net

作，直到满足某个终止条件为止。模拟退火遗传算法首先具有了GA 的全局搜索能力，其次具有了SA 的局部搜索能力，同时还能使SA算法充分利用GA的全局信息，对全局解空间有了详细了解。经验证，该算法在进化初期，使用遗传算法，温度较高，使得GA避免产生早熟收敛，增强了GA 的全局收敛性；在进化后期，使用模拟退火算法，温度较低，使得SA算法具有较强的爬山性能，加快了算法的收敛速度。最后针对TSP问题选用国际公认的TSPLIB的几个实例进行测试，均取得很好的效果，有的实例还找到了比TSPLIB提供的路径更优的路径。

4.2.1 遗传算法的改进

1 遗传算法循环模式的改进

1) 传统遗传算法循环模式：

```
while 当前代数<=最大代数
    {选择、交叉、变异}
    当前代数+1
end
```

2) 改进后的遗传算法循环模式：

```
参数设定，如: 初始温度t、减温系数k、结束温度tf
while 1
    {选择、交叉、变异}
    当前代数+1
    当前温度t=t*k
判断当前种群中最好个体的适应度是否小于前几代中最好个体，如果连续5代小于前几代最好个体的适应度，则结束循环，或者当前温度t<tf也结束循环
end
```

遗传算法后期的局部搜索效率是很低的，前期全局搜索效率是很高的。如果连续5代最好个体的适应度没有提高，说明遗传算法的搜索已经到了后期，则跳出遗传算法，接着用后面的退火算法进行继续搜索。退火算法前期的全局搜索效率很低，而后期的局部搜索效率很高，所以退火算法是接着遗传算法搜索完以后的温度以及得到的全局较优解进行继续搜索，这样，两个算法同时达到了互补，同时发挥了两个算法的优势。所以不管从效率和搜索时间上都大大提高了。

2 引入自适应的交叉和变异概率[51]

遗传算法中存在一个既对立又统一的问题：搜索效率与搜索空间的问题，即方向性与随机性的问题。增强方向性可提高遗传算法效率，增强随机性可增大遗传算法全局寻优的概率，这两者共同作用决定了遗传算法的性能。这两方面的均衡是分别由交叉概率 Pc 和变异概率 Pm 的值直接决定的。交叉概率 Pc 控制着交叉操作被使用的频率。较大的交叉概率可增强遗传算法开辟新的搜索区域的能力，但同时高性能的模式遭到破坏的可能性也增大；若交叉概率过低，遗传算法可能陷入迟钝状态。变异操作在遗传算法中属于辅助性的操作，其目的在于维持各群的多样性。一般，低频率的变异可防止种群中

中国知网 https://www.cnki.net

重要的、单一基因的可能丢失，高频率的变异会使遗传算法趋于纯粹的随机搜索。

为了使遗传算法具有更高的鲁棒性、全局最优性和效率，理想的情况是当算法提前收敛时，加大Pc和Pm，增大交叉和变异的概率，而在算法初期减小Pc和Pm，以免破坏遗传算法的搜索效率。对于高适应度的个体采用较低的Pc和Pm，以保持优良个体。对低适应度的个体采用较高的Pc和Pm，促进个体的进化。即Pc和Pm的大小不仅与算法收敛性有关，而且与个体适度也有关。本文引入针对Striniras提出的自适应交叉率和变异率而改进的自适应公式，如下：

$$p_c = \begin{cases} p_{c1} - \dfrac{(p_{c1} - p_{c2})(f' - f_{avg})}{f_{max} - f_{avg}}, & f' \geq f_{avg} \\ p_{c1}, & f' < f_{avg} \end{cases}$$

$$p_m = \begin{cases} p_{m1} - \dfrac{(p_{m1} - p_{m2})(f_{max} - f)}{f_{max} - f_{avg}}, & f \geq f_{avg} \\ p_{m1}, & f < f_{avg} \end{cases} \tag{4-1}$$

上式中 f_{max}：群体中最大的适应度值

f_{avg}：每代群体的平均适应度值

f'：要交叉的两个个体中较大的适应度值

f：要变异个体的适应度值

一般 p_{c1}=0.9， p_{c2}=0.6， p_{m1}=0.1， p_{m2}=0.001。根据实际问题，可作相应的调整。

从上式中可以看出，$f_{max}-f_{avg}$ 是衡量算法收敛程度的尺度。当算法收敛到局部最优值时 $f_{max}-f_{avg}$ 值将变小，此时应增加 Pc 和 Pm，使算法尽快脱离局部最优点。$f'-f_{avg}$ 或 $(f_{max}-f)$用来衡量个体的优良程度，当适应度值低于平均适应度值时，对应的 $f'-f_{avg}$ 或 $(f_{max}-f)$较大，说明该个体是性能不好的个体，对它就采用较大的 Pc 和 Pm；高适应的个体所对应的 $f'-f_{avg}$ 或$(f_{max}-f)$较小，此时 Pc 和 Pm 也减小以保证优良个体不因交叉和变异而破坏或丢失。

3 贪心 3PM(Parents Mating)交叉算子

贪心三交叉交配比传统交配方法增加了一个父代，期望产生适应性更加强的子代。算子的主要过程如下:

1) 一个子代的产生：

按轮盘赌选择法选择三个父体

父 代 1: 12345678

父 代 2: 87645321

父 代 3: 43127865

(1) 随机产生子代第一个位置(当前位置),假设为3，标准城市为3号城市;

(2) 向左轮转城市，使3个父代当前位置城市号与标准城市一致;

本例一次轮转后为:

中国知网 https://www.cnki.net

父 代 1: 34567812

父 代 2: 32187645

父 代 3: 31278654

(3) 假设distance(a,b)为城市a到b的距离，则比较distance(3,4),distance(3,2)和distance(3,1)，取最短的路径，假设distance(3,4)最短，则取标准城市为4，当前位置加1，跳转到步骤(2)继续轮转，类似地共执行n-1次，产生一个新个体。

2) 另一个子代的产生：

三个父代同上

(1)另一个子代最后一个位置(当前位置)与以上第一个子代的第一个城市号相同为3，标准城市为3号城市;

(2)向右轮转城市，使3个父代当前位置城市号与标准城市一致，

本例一次轮转后为:

父 代 1: 45678123

父 代 2: 21876453

父 代 3: 12786543

(3) 假设distance(a,b)为城市a到b的距离，则比较distance(3,2)和distance(3,5)和distance(3,4)，取最短的路径，假设distance(3,5)最短，则取标准城市为5，当前位置减1，跳转到步骤(2)继续轮转，共执行n-1次，产生另一个新个体。

从这一算法中可以看出，产生的两个子代都比较好地继承了3个父代的两方向的边，每次加入的边都是3个父代中最好的一条边，所以在执行初期，几乎是垂直收敛的，后代完全继承了前代的全部优秀的边。所以该算子的搜索效率非常高，在很短的世代内就能找到全局较优解。

4 退火选择

经过 3PM 交叉后就可以产生两个子代，子代是否就能代替父代呢，下面再进行选择，这里我们选用退火选择法

从三个父中随机选择两个，为父代 1 和父代 2，分别计算它们的适应度为 d(p1),d(p2),再计算两个子代的适应度 d(son1),d(son2)，为了简便，假设我们这里的适应度就是一条路径的距离。

退火选择法过程：

```
if d(son1)<=d(p1)
    new1=son1
    elseif (rand<exp[(d(p1)-d(son1))/t])
    new1=son1
    else
    new1=p1
end
```

对于子代 2 用同样的方法,最终得到下一代的两个个体。

中国知网 https://www.cnki.net

4.2.2 模拟退火算法的改进

1 初始种群的改进

退火算法初始种群是在遗传算法执行结束后的全局较优解，退火算法是对这种全局较优解进行局部搜索，最终找到最优个体。充分发挥退火算法的高效的局部搜索能力。

2 冷却进度表

一个冷却进度表应当规定下述参数

1) 控制参数Tk 的初温T0；

2) 控制参数Tk 的下降函数Tk+1=d(k)

3) 马尔科夫链的长度Lk。

下面我们对其分别讨论:

(1) 关于控制参数Tk 的初温T0

在这里采用这样一种初温赋值法：

T0=(maxdist-mindist)*CityNum

这里 maxdist 是所有城市中距离最大值，mindist 是所有城市中距离最小值，在这里我们可以取 0，CityNum 是城市的个数。退火算法中使用的是遗传算法执行结束后的温度作为它的初始温度。

(2) 关于控制参数 Tk+1

在这里我们直接取 Tk+1= Tk*K,K 取值为接近于 1 的一个数，在实验中一般取 0.95 左右。

(3) 马尔科夫链的长度 Lk

对于Markov 链的长度Lk,一般使用Lk=γ*n，其中n为自变量维数。这里的γ一般取100。n一般为城市数。

3 结束条件的改进

通过前面我们知道模拟退火算法的结束条件就是当前温度小于结束温度，但我们通过大量实验发现，退火算法在离结束温度很远处就已经找到最优解了，后面大量的全是无用的循环，不但没有改变最优解质量，而且占用了大量时间有空间，在这里我们再加上一个结束条件，使得搜索时间大大减少。

退火过程：

```
while 1
    记录当前代个体的适应度（城市距离）
    退火处理
    if 新的个体的适应度（城市距离）＝当前代个体适应度（城市距离）
        same=same+1
    else
        same=0
    end
    if same==5||t<tf
        break;
```


中国知网 https://www.cnki.net

end

通过大量实验已经证明，当连续五代个体与前一代个体城市距离无变化时，说明最优解已经找到，后面再多的退火处理也是在做无用功。

4.2.3 基于 GCBSAGA 的 TSP 问题求解

1 GCBSAGA 描述

GCBSAGA 算法的过程是随机产生一组初始群体，通过选择、贪心 3PM 交叉、变异等改进的遗传算子来产生一组新的个体，这样不断循环，直到产生的新群体的最优个体比父代差，之后选择最优个体，独立的对其进行模拟退火操作，直到满足结束条件。遗传退火进化算法不但实现了 GA 的全局搜索能力与 SA 的局部搜索能力的结合，同时可使改进后的 SA 能够充分利用 GA 所得的全局信息。

2 GCBSAGA 的流程

改进的模拟退火遗传算法的具体流程如下：

begin

1) 初始化各参数，如交叉概率 pc1、pc2，变异概率 pm1、pm2，最大代数 gemax，种群规模，初始温度 t,结束温度 tf，降温系数 k 等等。

2) 随机初始化种群 p,s 代表一个染色体(个体)或叫一条路径，p={s0,s1,s2 …… sn}；

3) 计算各染色体的适应度 f(i)，记录最好染色体 fit_max；

4) 产生新的种群：

(1) i=1:2:n；

(2) 轮盘赌选择法，选择三个父代；

(3) 对三个父代按照自适应方法产生的交叉概率运用贪心 3PM 交叉算法进行交叉产生两个新个体；

(4) 对交叉后的个体运用退火选择，产生下一代的两个个体；

(5) 对选择后的两个个体按照自适应的变异概率进行变异；

(6) 转到(1)进行下一次迭代，直到产生了 n 个个体，形成了下一代种群；

5) 当前代数加 1，当前温度 t=t*k；

6) 判断当前代中最好个体的适应度（城市距离）>=最好染色体 fit_max 的城市距离：

(1) 如果判断是,则 tuihua=tuihua+1；

(2) 否则 tuihua=0，最好染色体 fit_max 的城市距离＝当前最好个体城市距离；

7) 判断 tuihua==5 或 t<tf：

(1) 如果判断是，则 break，结果遗传循环；

(2)否则转到第 3)步；

8) 计算经过遗传算法后得到的全局较优个体的城市距离；

9) 调用退火算法，全局较优个体的城市排列、当前温度、结束温度、减温系数、城市间距离及坐标等均作为参数传入退火算法中；

10) 在模拟退火算法中，初始化马尔科夫链的长度 L，接收传来的参数值；

11) 进入模拟退火算法的循环：

中国知网 https://www.cnki.net

(1) 记录前代最好的个体的城市距离；

(2) 进入内循环即：马尔科夫链的循环；

a 产生新个体，这里我们仍采用倒位法产生新个体，即随机产生两个位置，使这两位置之间的所有城市颠倒位置；

b 计算新产生的个体的城市距离，并与前一代中个体的城市距离相差，得到changetd；

c 判断 changetd<0：

如果判断是，则将新产生的个体代替前一代个体，城市距离代替前一代个体的城市距离；

否则再判断 rand<exp (-changetd/t),如果正确，同样将新产生的个体代替前一代个体，城市距离代替前一代个体的城市距离；

d 转到第 a 步，继续循环，直到满足结束条件，跳出内循环；

(3) 当前温度降温，t=t*k；

(4) 判断当前个体的城市距离＝＝前一代城市距离，就是看看个体有没有发生变化：

判断为是，则 same=same+1；

否则 same=0；

(5) 判断 same==5 或 t<tf：

如果判断是，则结果外循环；

否则跳转到第 11.1 步；

12) 输出最好个体的城市路径及距离，并用图示画出。

end

3 GCBSAGA 的特点

(1)将遗传算法的循环模式作改进，引入了模拟退火算法的循环模式，这样就可以引用温度这样一个概念，使得高温时，利用遗传算法进行全局搜索能力，很快地能够收敛到全局较优个体。

(2)遗传算法中交叉算子的改变，不仅考虑到城市的位置关系，而且也考虑到了城市之间边的关系。加入了退火选择，而且左轮转右轮转同时进行，产生了两个完全地继承三个父代两边信息的子代，形成一种新的交叉算子—贪心 3PM 交叉算子，这一算子之所以称得上贪心，除了退火选择外，还因为它的高效的全局搜索能力，在很短的世代内就能搜索出全局较优个体。

(3)利用退火算法对遗传算法的全局较优个体独立进行处理。在高温时，也就是前期利用遗传算法进行全局搜索。在低温时，也就是中后期利用退火算法对遗传算法产生的全局较优个体进行局部搜索，充分利用了退火算法后期局部搜索的高效性。最终收敛于全局最优解。

中国知网 https://www.cnki.net

4.3GCBSAGA 算法的分析

4.3.1 混合遗传算法的构造原则

目前智能优化算法很多，爬山法、梯度法、模拟退火法等一些优化算法具有很强的局部搜索能力，而另一些含有与问题相关的启发知识的启发式算法的运行效率也比较高。如何融合这些优化算法的思想，构成一种新的混合遗传算法，是提高遗传算法求解质量和运行效率的一个有效手段。目前，混合遗传算法的实现方法体现在两个方面，一是引入局部搜索过程，二是增加编码变换操作过程。在构造混合遗传算法时，De Jong[52]提出以下三个基本原则：

(1)尽量采用原有算法的编码。

(2)利用原有算法全局搜索的优点。

(3)改进遗传算子。

本文之所以选择 SA 与 GA 相结合，主要原因可归纳为以下几方面[43]。

(1)优化机制的融合。理论上，GA 和 SA 这两种算法均属于基于概率分布机制的智能优化算法。不同的是，SA 的搜索过程具有一种时变而最终趋于零的概率突跳性，从而可以有效避免陷入局部最优的危险并且最终能趋于全局最优；GA 的优化过程是通过概率意义下的基于“优胜劣汰”思想的群体遗传操作来实现。将这两种在选择优化机制上如此差异的算法进行混合，有利于丰富优化过程中的搜索行为，增强局部和全局意义下的搜索效率和能力。

(2)优化结构的互补。GA 采用群体并行搜索，而 SA 算法采用串行优化结构。两者相结合，能够使 SA 成为并行 SA 算法，提高其优化效率和性能；同时 SA 作为一种自适应变概率的变异进化操作，补充和增强了 GA 的进化能力。

(3)优化操作的结合。SA 算法的状态产生和接受新解操作在每一时刻仅保留一个解，缺乏历史搜索信息和冗余；而 GA 的选择操作则能够在下一代中保留上一代种群中的优良个体，交叉操作能够使子代在一定程度上继承父代的优良模式与特征。变异操作能够提高种群中个体的多样性。这些不同功能的优化操作相结合，丰富了优化过程中的领域搜索结构，且增强了全空间的搜索能力。

(4)优化行为的互补。由于选择操作对当前种群外的解空间无探索能力、当种群中各个体分布“畸形”时交叉操作的进化能力也是有限的，且小概率的变异操作也很难增加种群的多样性。所以，一方面，若 GA 算法的收敛准则设计不好，会经常出现进化缓慢或“早熟”收敛的现象，另一方面，SA 算法的优化行为对退温历程具有很强的依赖性，而全局收敛在理论上已经被证明对退温历程的限制条件非常苛刻，因而 SA 优化时间性能比较差。若两种算法相结合，那么，SA 算法的两准则可控制 GA 算法的收敛性，避免出现“早熟”收敛现象；而 GA 并行化的抽样过程又可提高 SA 算法优化的时间性能。

(5)削弱参数选择的苛刻性。GA 和 SA 对算法参数的选择具有很强的依赖性，参数选择的不合适将严重影响优化性能。GA 的参数选择没有明确的选择指导，不同问题设计算法时均要通过大量的试验和经验来确定；而 SA 的收敛条件又导致算法参数选择较

中国知网 https://www.cnki.net

为苛刻，甚至不实用。GA 和 SA 相结合，使算法各方面的搜索优化能力均有所提高，因此对算法参数的选择就可以不必过分严格。

4.3.2 算法 GCBSAGA 的优点

通过以上分析，算法 GCBSAGA 具有以下优点：

(1) GCBSAGA 算法是标准 GA、SA 以及并行 SA 算法的一个统一结构。若在 GCBSAGA 算法中移去有关 SA 的操作，则 GCBSAGA 算法就转化为 GA 算法；若移去 GA 的进化操作，则转化为并行 SA 算法；进一步讲，若设置种群数为 1，则转化为标准 SA 算法。

(2) GCBSAGA 算法本质上是一个两层并行搜索结构。进程层次上，GCBSAGA 算法在各温度下串行地依次执行 GA 和 SA 搜索，是一种两层串行结构。其中，SA 的初始解来自 GA 进化后的结果，SA 的初始温度为 GA 进化结束后的温度，SA 经 Metropolis 抽样过程得到的解成为全局最优解。空间层次上，GA 提供了并行搜索结构，使 SA 转化成并行 SA 算法，因此 GCBSAGA 算法始终进行群体并行优化。

(3) GCBSAGA 算法利用了不同的领域搜索结构。GCBSAGA 算法结合了 GA 和 SA 两个算法的搜索，其优化过程中既包含了 GA 的选择、交叉、变异又包括了 SA 的状态产生函数等不同的领域搜索结构。选择操作有利于优化搜索过程中产生优良个体的冗余信息，交叉操作有利于后代继承父代的优良模式和特征，高温下的 GA 操作有利于优化搜索过程中状态的全局大范围迁移，变异和低温下的 SA 操作有利于优化搜索过程中状态的局部范围趋化性移动，所有这此都有助于增强 GCBSAGA 算法在解空间中的搜索能力和优化效率。

(4) GCBSAGA 算法的搜索行为是可控的。GCBSAGA 算法的搜索行为，可通过退温历程(即初温、退温函数和抽样次数)加以控制。控制初温，可以控制算法的初始搜索行为；控制温度的高低，可以控制算法突跳能力的强弱，高温下具有强突跳性有利于避免陷入局部最优，低温下的趋化性寻找有利于提高局部搜索的能力；控制温度的下降速率，可控制突跳能力的下降幅度，影响搜索过程的平滑性和稳定性；控制抽样次数，可控制各温度下的搜索能力，影响搜索过程中对应的马尔科夫链的平稳概率分布。这种可控性增强了克服 GA 算法易“早熟”收敛的能力。

(5) GCBSAGA 算法利用了双重准则。理论上，抽样稳定准则和算法终止准则均由收敛条件决定，但是这些条件往往不实用。在设计算法时，抽样稳定准则可以用来判定各温度下算法的搜索行为和性能；算法终止准则可以用来判定算法优化性能的变化趋势和最终优化性能。两个准则相结合可同时控制算法的优化性能和效率。

由此可见，在优化的机制、结构和行为上，GCBSAGA 算法均结合了 GA 和 SA 的特点，使两种优化算法的搜索能力得到相互补充，弥补了各自的弱点。因此 GCBSAGA 算法是一种优化能力、效率和可靠性较高的优化方法。

4.4 交叉算子收敛性分析

下面的实验所有参数都设置相同，采用目前典型的3种交叉算子与贪心3PM交叉算

中国知网 https://www.cnki.net

子进行对比实验。

这三种典型交叉算子已经在4.1.2节中有所介绍，分别是：部分匹配交叉(PMX)、郭涛交叉(GTX)、循环交叉(CX)。为了充分说明贪心3PM交叉算子的高效性，这里选用国际公认的TSPLIB库[53]中的pr144 、eil76 、eil101、st70、Berlin52，这五个不同类型不同规模的实例进行实验。下面是5种实例分别用这4种不同交叉算子进行100代测试得到的搜索过程曲线图。

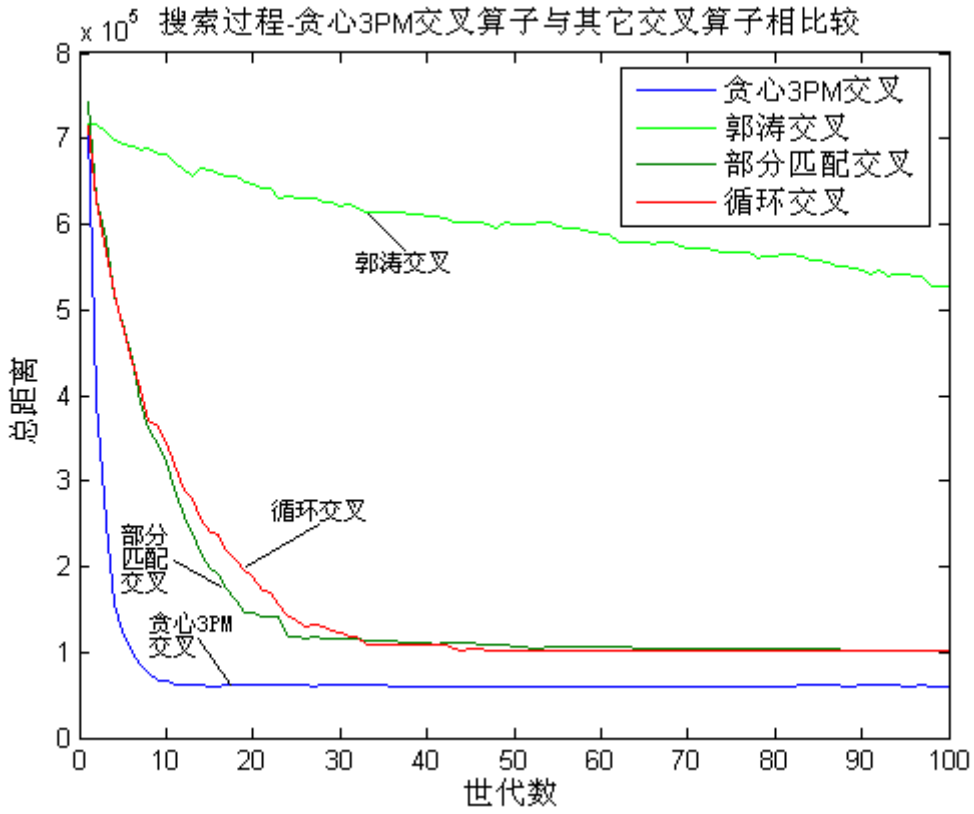

图4-1 实例pr144采用4种不同的交叉算子得到的搜索过程曲线图

Fig.4-1 the search graph of instance pr144 is used of four kinds of different crossover operator

中国知网 https://www.cnki.net

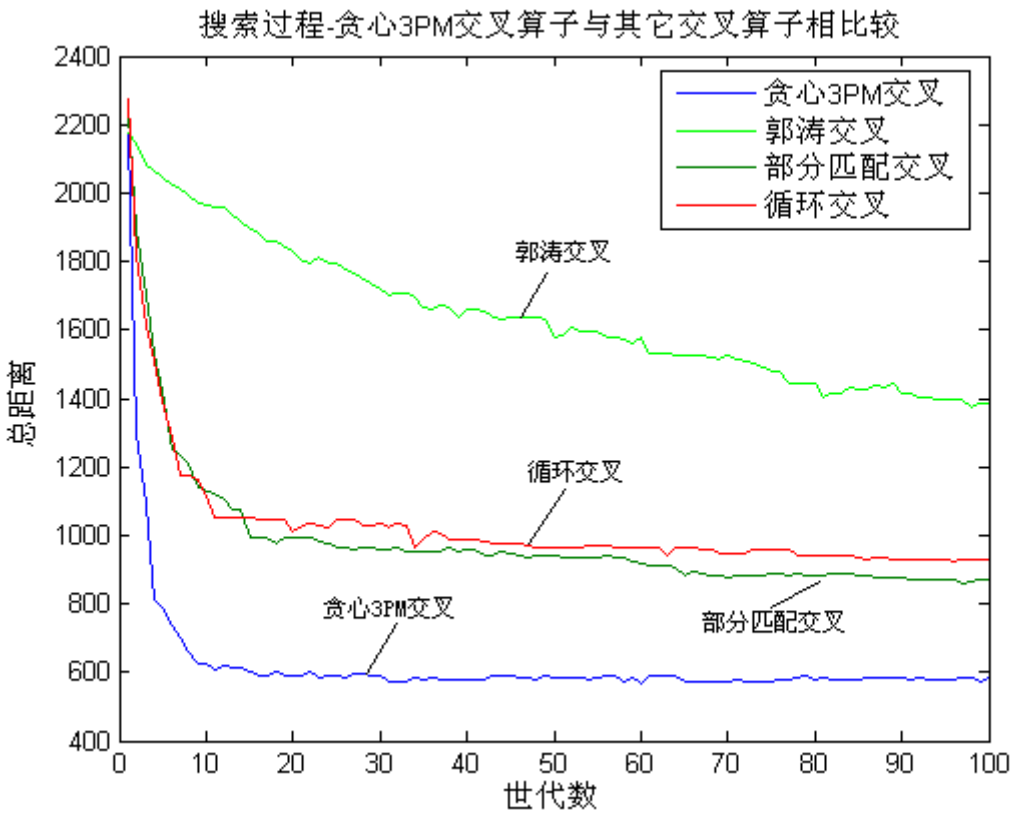

图4-2 实例eil76采用4种不同的交叉算子得到的搜索过程曲线图

Fig.4-2 the search graph of instance eil76 is used of four kinds of different crossover operator

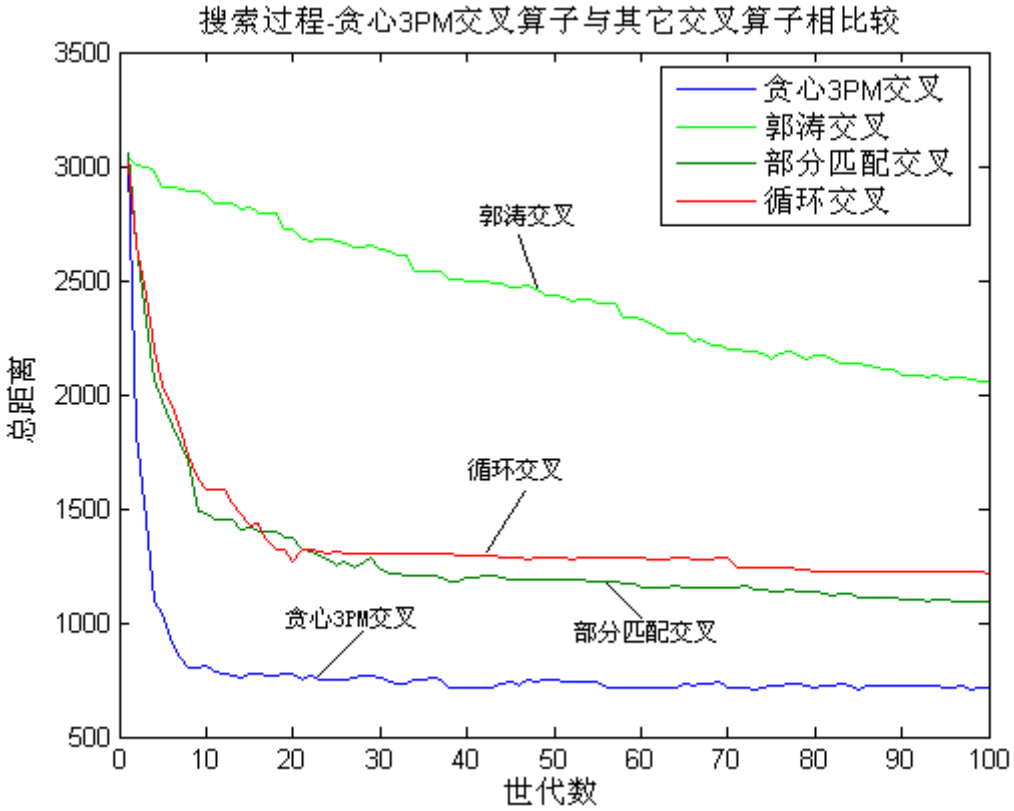

图4-3 实例eil101采用4种不同的交叉算子得到的搜索过程曲线图

Fig.4-3 the search graph of instance eil101 is used of four kinds of different crossover operator

中国知网 https://www.cnki.net

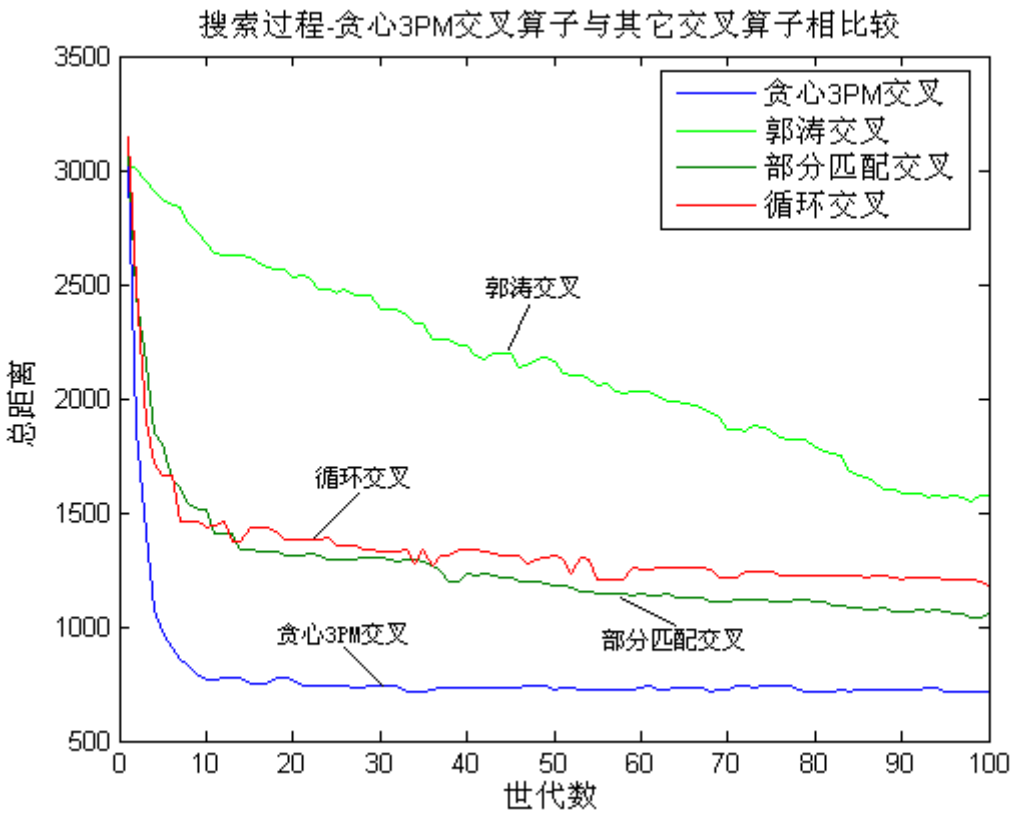

图4-4 实例st70采用4种不同的交叉算子得到的搜索过程曲线图

Fig.4-4 the search graph of instance st70 is used of four kinds of different crossover operator

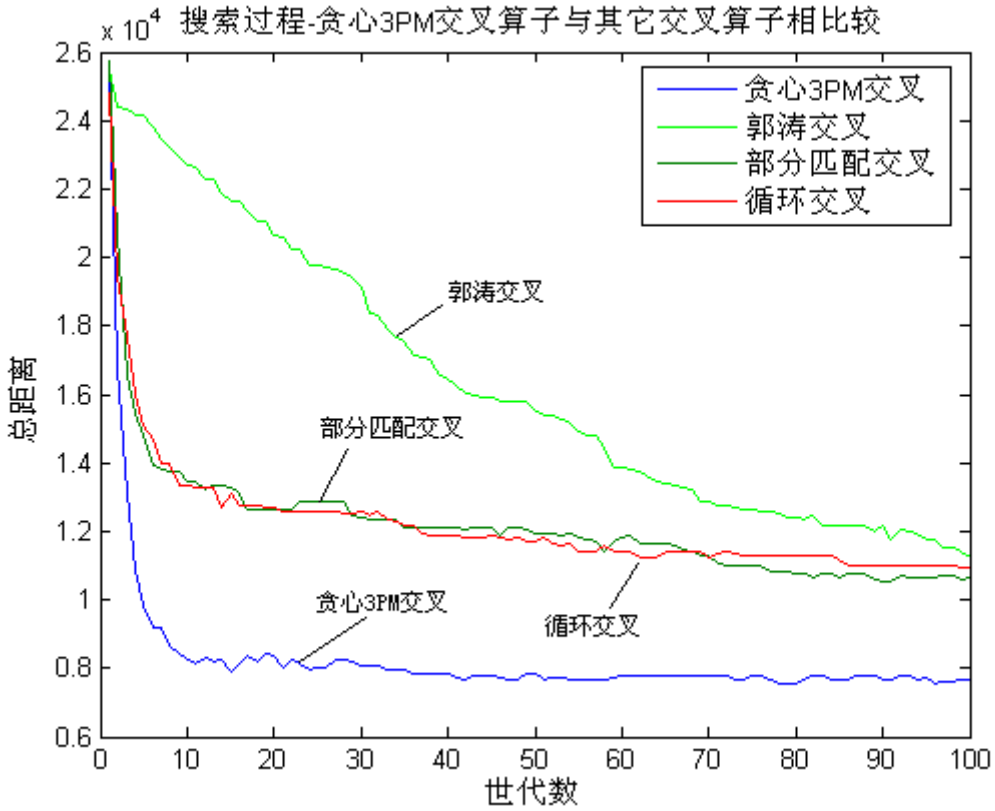

图4-5 实例Berlin52采用4种不同的交叉算子得到的搜索过程曲线图

Fig.4-5 the search graph of instance Berlin52 is used of four kinds of different crossover operator

中国知网 https://www.cnki.net

从以上5个典型实例eil76、eil101、pr144、st70、Berlin52中可以看出，贪心3PM交叉算子的收敛速度均比其它三个交叉算子要快，基本在十几代就能找出全局较优解。该算子在迭代初期几乎是垂直收敛，相对其它交叉算子效率高了很多。

贪心3PM交叉算子是基于边的交叉算子，采用双向轮转的方法，使子代能够比较好地继承了3个父代的边信息。每次加入的边都是3个父代中最好的一条，而且在子代取代父代的种群替换上还采用退火选择进行处理，相当于又加了一道防退化的墙，使得子代几乎不会出现退化的现象，一代比一代的适应能力强。

4.5 实验结果与分析

为了更好地说明该算法的有效性，我们选用了国际上通用的 TSP 测试库 TSPLIB 中的多个实例进行测试。

实验中的参数设置为：种群大小 inn=80，最大世代数 gnmax=100，交叉概率 pc1=0.9,pc2=0.7，变异概率 pm1=0.2, pm2=0.1，结束温度 tf=0.01，降温系数 k=0.95。

TSPLIB 中的实例 pr144 、eil76 、eil101、 st70、Berlin52 均用 GCBSAGA 算法经过 10 次测试后所得最优路径值与 TSPLIB 提供的最优路径值的比较见表 4-1。

表 4-1 TSPLIB 提供的路径值与 GCBSAGA 所得最优路径值比较

Tab.4-1 the comparison is between the path value of TSPLIB and the optimal path value of GCBSAGA

实例	TSPLIB 提供的最优路径值	GCBSAGA
pr144	58537	58535
eil76	545.3876	544.4560
eil101	642.3095	640.5958
st70	678.5975	677.1945
Berlin52	75444	75444

上述实例 pr144、eil76 、eil101、st70、Berlin52 经过 GCBSAGA 测试后所得的最优路径图分别见图 4-6、图 4-7、图 4-8、图 4-9、图 4-10。

中国知网 https://www.cnki.net

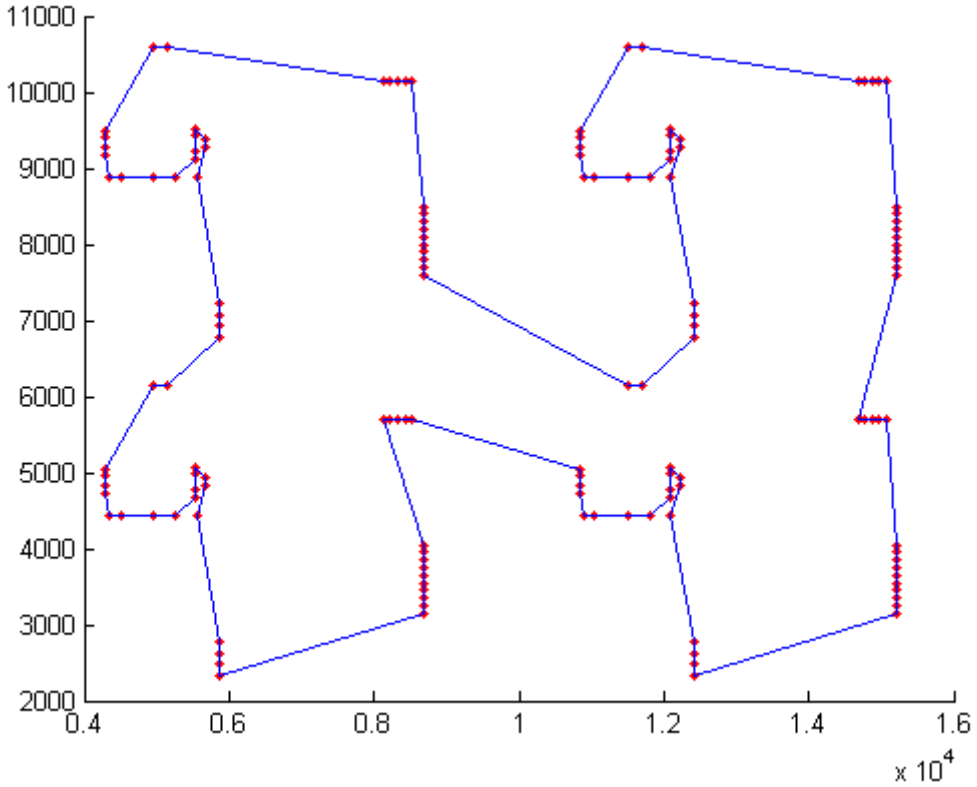

图 4-6 pr144 实例经过 GCBSAGA 算法得到的最优路径图

Fig.4-6 the optimal path graph of instance pr144 is by GCBSAGA

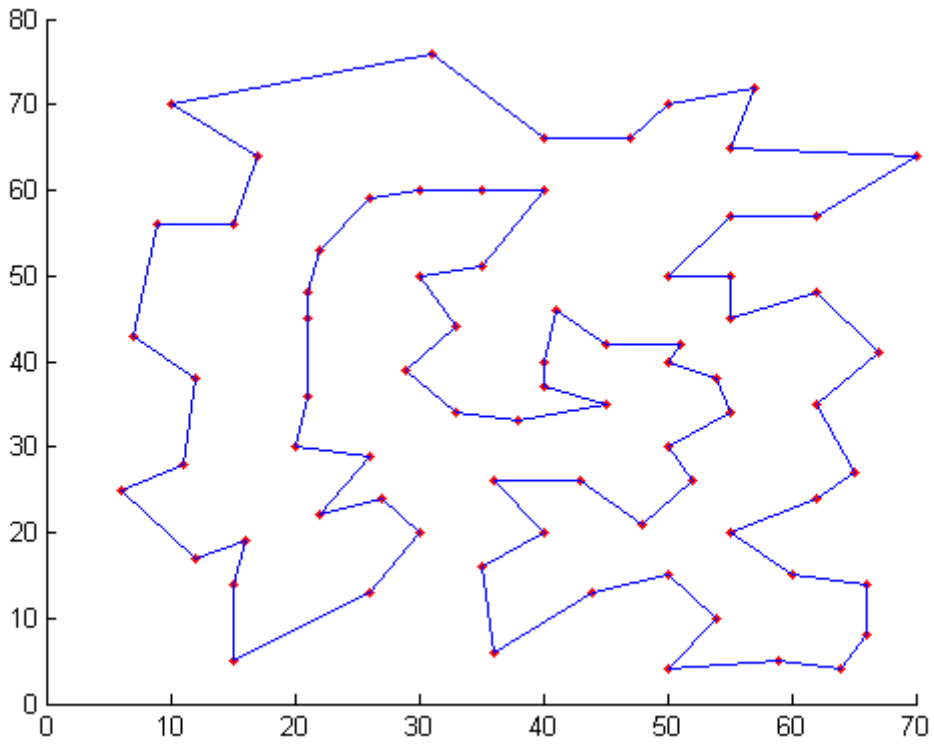

图 4-7 eil76 实例经过 GCBSAGA 算法得到的最优路径图

Fig.4-7 the optimal path graph of instance eil76 is by GCBSAGA

中国知网 https://www.cnki.net

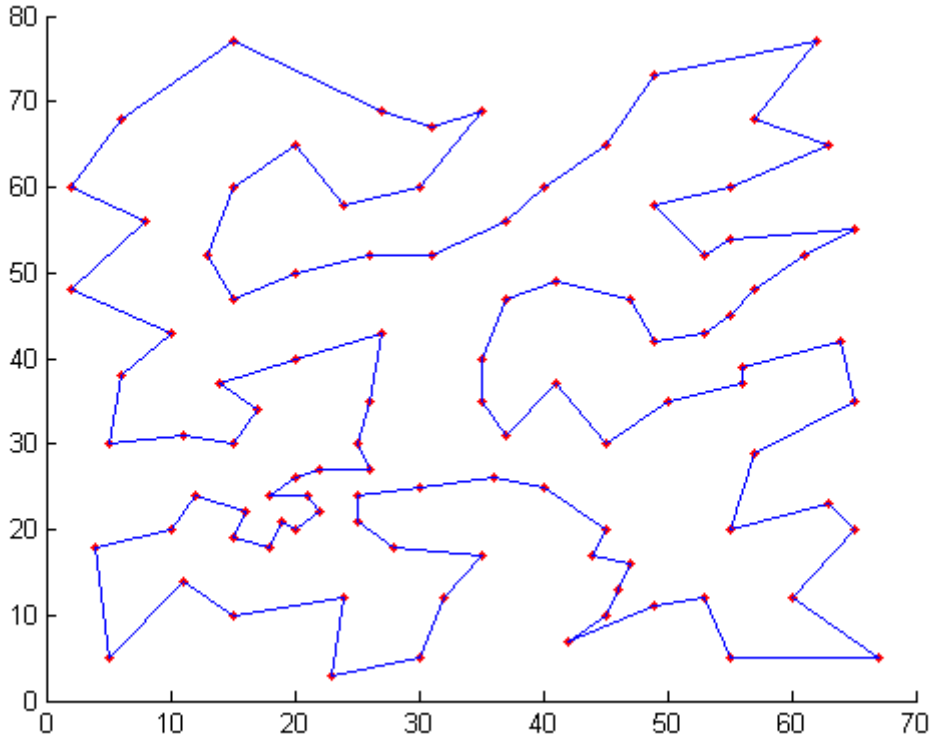

图 4-8 eil101 实例经过 GCBSAGA 算法得到的最优路径图

Fig.4-8 the optimal path graph of instance eil101 is by GCBSAGA

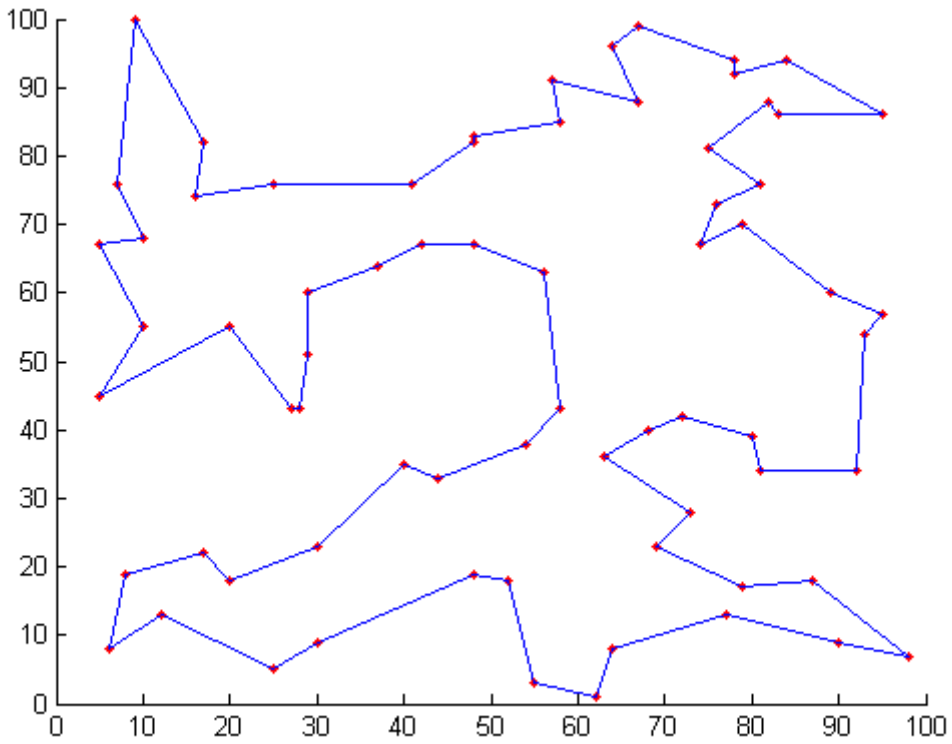

图 4-9 st70 实例经过 GCBSAGA 算法得到的最优路径图

Fig.4-9 the optimal path graph of instance st70 is by GCBSAGA

中国知网 https://www.cnki.net

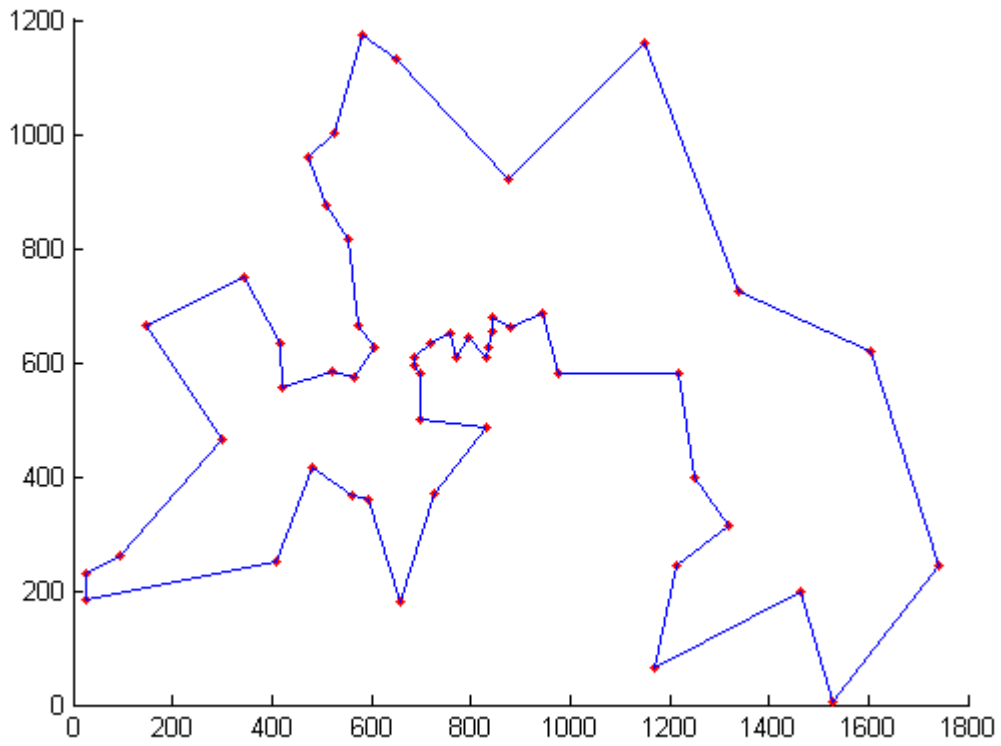

图 4-10 Berlin52 实例经过 GCBSAGA 算法得到的最优路径图

Fig.4-10 the optimal path graph of instance Berlin52 is by GCBSAGA

从以上 5 个典型实例中可以看出 eil76、eil101、pr144、st70 实例经 GCBSAGA 算法测试得到的最优路径长度均优于 TSPLIB 提供的最优路径经计算后的值。Berlin52 实例经 GCBSAGA 算法试得到的最优路径长度与 TSPLIB 提供的最优路径经计算后相同。正是因为前期遗传算法全局搜索的高效性，再加上后期模拟退火算法局部搜索的爬山能力，使得 GCBSAGA 算法在较短的时间内完成了最优路径的寻找。

GCBSAGA 算法通过对遗传算法和模拟退火算法进行改进，而且合理地使得这两种算法相结合，扬长避短，形成一种基于 3PM 交叉算子的模拟退火遗传算法(GCBSAGA)。该算法中对遗传算法的循环结构的改进，巧妙地引入了温度的概念；对交叉算子的改进，引入了贪心选择算法，形成了贪心 3PM 交叉算子，使得遗传算法的全局搜索效率得到很大提高，使得找到最优解的时间大大减少。对遗传算法后的较优解经过退火算法的局部搜索，便能很快得到最优解，充分发挥了退火算法低温局部搜索的高效性。经过实验可以证明 GCBSAGA 算法的高效性，很快就能找到最优解，而且能找到更好的解，很好地解决了传统遗传算法中运算时间过长、收敛较慢、最终找不到最优解有可能出现早熟的问题。

中国知网 https://www.cnki.net

第五章 GCBSAGA 算法在配送和回收一体化车辆路径中的应用

配送和回收一体化的车辆路径问题(VRPSDP)是一种非常复杂的 NP 难题。针对这一实际性问题，本文将运用上一章提出的基于 3PM 交叉算子的模拟退火遗传算法(GCBSAGA)来解决此问题。针对 VRPSDP 问题的特殊性，在这一章中将对 GCBSAGA 算法进行改进，以适用于求解此类问题。编码方案上采用非零自然数编码机制和弱可行解到强可行解的解码机制，引进 insert 、swap 和 2-opt 变异方法分别对模拟退火的当前解进行迭代优化。经过国际公认的测试算例验证，GCBSAGA 算法在 Min 算例、Salhi 和 Nagy 算例中均找到了比现有算法已知最好解更优的解。

5.1 VRPSDP 问题概述

车辆路径问题[54]（Vehicle Routing Problem, VRP）是一个非常具有魅力的组合优化问题，它已经被证明是一个 NP 难题。该问题吸引着全世界无数的科学家、管理者和工程师为之探索，一直是管理学、运筹学、计算机科学等领域的研究热点问题。自 1959 年由 Dantzig[55]提出后，这几十年来这方面已取得大量研究成果。在现实生活中有着广泛的应用，如物流配送、校车路径安排、邮政投递、飞机和铁路的调度等，是一个具有非常重要理论意义和实际应用价值的研究课题。

随着可用自然资源的日趋减少以及人们环保意识的不断增强，材料和产品的回收再利用成为当前的焦点，由此形成一种逆向物流的概念，是指与传统供应链反向，为价值恢复或处置合理而对原材料、中间库存、最终产品及相关信息从供应链下游的消费一端返回上游生产一端的有效实际流动所进行的计划、管理和控制过程。这一问题已经成为当前各国物流领域的一个新热点。随着逆向物流的发展，近年来 VRP 问题也出现了另一形式的问题，即：配送和回收一体化的车辆路径问题[56]（Vehicle Routing Problem with Simultaneous Delivery and Pickup，VRPSDP）。这一新问题的出现引起了全世界研究者的关注。自从 Min[57]针对一个关于图书馆配送的实例首次定义了该问题，在以后的十年中，几乎没有关于该问题的讨论。而逆向物流的兴起，使得所有的研究者重新开始对该问题进行研究和探讨。文献[57]-[60]讨论了该问题的若干应用实例。由于 VRP 问题是 NP 难题，因此，VRPSDP 也是 NP 难题，而且比基本 VRP 问题更复杂。

目前对 VRPSDP 问题的求解方法主要有：构造性算法，如文献[61]中的先聚类后插入算法，文献[62]中 Dethloff 提出的带有参数的插入法(HA) ；禁忌搜索，如文献[63]中 Tang Montané 等提出的基于四种邻域结构和两种搜索策略的禁忌搜索，文献[64]中 Crispim 等提出的基于禁忌搜索的混合算法，文献[65]中 Chen 和 Wu 提出了一种基于“记录”和禁忌表的混合启发式算法。最近，Bianchessi 和 Righini 提出了一些局部搜索算法、构造性算法以及禁忌搜索算法并加以比较，其中重点是讨论了基于复合多邻域结构的禁忌搜索算法[66]。Tang Montané[63]等人给出一组测试算例解的下界，这些下界表明，虽然现有算法能够在一定程度上解决 VRPSDP 问题，但在求解质量上还有较大的改进空间。

本章将上一章节中提出的改进模拟退火遗传算法(GCBSAGA)运用到 VRPSDP 问题

中国知网 https://www.cnki.net

中，并针对这一问题的特殊性，对 GCBSAGA 算法作改进。这里采用非零自然数编码方案，加入解码机制，这样就能很清楚地表现出问题的解。并引入本论文中提出的贪心 3PM 交叉算子，提高遗传算法的搜索效率。同时将其与模拟退火算法相结合，形成针对 VRPSDP 问题的 GCBSAGA 算法。这一算法不但充分利用了模拟退火算法强大的局部搜索能力，对遗传算法得到的全局较优解进行局部搜索最终得到最优解，而且还利用一个编码和解码机制，将复杂的表现方法变得简单化，而且便于分析。最后选用国际公认的 VRPSDP 的实例进行测试，均得到比现在有算法更好的解，验证了算法的有效性。

5.2VRPSDP 问题描述

对于装卸一体化的车辆路径问题，在配送过程中，配送车辆经过每一客户时，可以先将该客户需求的那部分货物卸下，然后装上该客户供应的那部分货物，即车辆可在送货的同时完成取货任务。由于货物的装卸作业是在配送车辆的一端进行的行为，所以配送车辆在装卸货物过程中进行货物倒装整理是不可避免的。为了减少配送中的差错并减少货物的倒装工作量，配送车辆在整个取送货过程中应遵循“后到先装”的原则：在物流中心装各个客户需求的货物时，需将后到客户需求的货物装在车辆的里端，将第一个客户需求的货物装在车辆的最外端；到达第一个客户后，先将该客户需求的货物卸下并交货，然后通过倒装整理作业将该客户供应的货物装在车辆的里端，将下一个客户需求的货物装在车辆的最外端；依此类推，直到车辆完成取送货任务。

5.2.1VRPSDP 问题描述

描述 VRPSDP 问题[67]的假设：

(1)有 N 个顾客等待服务，N={1，2，…，n}；d_i 为顾客 i 的配送需求(从服务中心出发) $d_i \geq 0$；p_i 为回收需求（目的地为服务中心），$p_i \geq 0$，$\forall_i \in$N。

(2)节点为 0 的为服务中心，d_0=0，p_0=0。

(3)费用 c 由任意两个顾客或顾客与服务中心之间的距离表示，在此，假定费用矩阵是对称的，即：

$c_{ij} = c_{ji}$，$\forall i, j \in N_0 = N \cup \{0\}$；i<j

(4)集合 V 为车辆集合。在此，假设车辆的数量足够多，且所有车辆容量 Q 都相同。Q$\geq \max\{d_i, p_i\}$，$i \in N$

VRPSDP 规划模型的目标是设计一系列费用最小化的车辆路径，使得：

(1)每一条路径都从服务中心出发并最终回到服务中心。

(2)每一条路径(每一辆车)的最大载货量都必须小于或等于 Q。

(3)每一个顾客被且只被服务一次。

5.2.2 可行性解

设$s = \{r_i | i = \{1, ..., k\}\}$是 VRPSDP 问题的一个解，其中 r_i 对应一条车辆路径。从 VRPSDP 问题描述可知，s 是 VRPSDP 问题的一个可行解的充分必要条件是：对任意 r_i，都满足

1) r_i 上所有客户的卸货需求总和 D(x)不超过 Q；

中国知网 https://www.cnki.net

2) r_i上所有客户的装货需求总和 P(x)不超过 Q；

3) 车辆访问 r_i上任何客户之后，其载重量都不能超过 Q。

若$\forall r_i \in s$都满足条件（1）（2）（3），则称 s 满足强可行性条件，是强可行解；若$\forall r_i \in s$都满足条件（1）（2），但$\exists r_i \in s$不满足条件（3），则称 s 满足弱可行性条件，是弱可行解。由于 Mosheiov[3] 已经证明，如果 D(x) 和 P(x)都不超过车辆容量限制，则 r_i一定可以通过某种方式转化成为可行路径。因此，若 s 是弱可行解，则一定可以通过某种方式转化为强可行解。

5.2.3 弱可行性解转化为强可行性解

算法 GCBSAGA 中利用与文献[65]相同的方法将弱可行解转化成强可行解，即从头到尾逐个扫描每一条路径 r 上的所有客户，若访问当前客户后 r 不能满足强可行性条件，则跳过当前客户扫描下一个；否则，当前客户扫描完后继续扫描下一个；最后，如果刚才扫描过程中有跳过的客户，则按照逆序将在第一次扫描中被跳过的所有客户逐个重新加入 r，即可得到一个强可行解。

5.3 求解 VRPSDP 的 GCBSAGA 算法

5.3.1 遗传算法的编码解码机制及初始种群

本文采用实数表现个体的方法，服务中心为0，客户从1－n编号，初始种群的编码是随机产生n个客户的一个全排列。编码过程是随机的，全排列中没有服务中心0，服务中心0在解码过程中加入。这样的编码机制有效避免产生无效解的情况，即全排列中连续出现两个或两个以上0的情况。

解码机制是在1－n编号的全排列客户中，按从左到右的先后顺序依次访问，在正确的位置处插入0(服务中心)。首先要使一条路径r上被访问的客户满足弱可行解的条件，再将弱可行解的客户按上述方式转化为强可行解，最后将此强可行解的两端加上0(服务中心)，形成新的访问序列，即形成了一辆车的行驶路径，未访问的客户按从左到右的先后顺序依次访，按上述过程进行处理，直到所有客户被访问，此时解码结束。如编码后路径为：14382576，解码后的路径为：013408520760，这条解码后的染色体表示由3车辆完成8个用户任务的路径安排：1号车子路径：服务中心－客户1－客户3－客户4－服务中心；2号车子路径：服务中心－客户8－客户5－客户2－服务中心；3号车子路径：服务中心－客户7－客户6－服务中心。

5.3.2 模拟退火算法的变异方法

在模拟退火算法中，需要不断产生新的个体，采用什么样的策略产生新个体，关系到此算法的搜索能力问题。算法 GCBSAGA 中分别使用三种求解 VRPSDP 问题新个体时常用的方法：插入（insert）、交换（swap）和 2-opt。

1)插入 (insert)

中国知网 https://www.cnki.net

将解 s 中的某个客户 i 从当前位置 p_1 移到 s 的另一个位置 p_2，产生新解s'。例如，解 s = 8－$\boxed{3}$－5－7－9－$\underline{1}$－2－4－6－10，将客户 3 从当前的 2 号位置移到 6 号位置，产生新解s' = 8－5－7－9－1－$\boxed{3}$－2－4－6－10。

2)交换（swap）

将解 s 中的客户 i 和 j 的位置互换，产生新解s'。例如，解 s = 8－$\boxed{3}$－5－$\boxed{7}$－9－1－2－4－6－10，交换客户 3 与 7，产生新解s' = 8－$\boxed{7}$－5－$\boxed{3}$－9－1－2－4－6－10；

3)2-opt

解 s 中同一路径上的两个客户 i 和 j，在解 s 中的位置分别为 p_i 与 p_j（$p_i < p_j$）。2-opt 是指将 p_i+1 位置上的客户与 j 交换，并将 p_i+1 和客户 j（不包括 p_i+1 位置上的客户和客户节点 j）之间的客货节点按逆序访问。例如，解 s = 8－$\boxed{1}$—9－5－7－$\boxed{4}$－12－$\boxed{2}$－6－3－8－$\boxed{10}$－11－13，对两条路径分别通过 2-opt 优化后，得到新解s' = 8－1－$\underline{4}$－7－5－$\underline{9}$－12－2－$\underline{10}$－8－3－$\underline{6}$－11－13。

分别使用三种策略来产生新个体，能大大提高新个体的适应度，这样使模拟退火算法的局部搜索能力再次提高，能在较快的时间内找到最优个体，避免了基本模拟退火算法运算时间长的弱点。

5.3.3 求解 VRPSDP 的 GCBSAGA 算法流程

求解 VRPSDP 问题的 GCBSAGA 具体流程如下：

begin

1) 初始化各参数，如交叉概率 pc，变异概率 pm，最大代数 gemax，种群规模，初始温度 t,结束温度 tf，降温系数 k 等等；

2) 采用非 0 自然数编码，随机初始化种群 p,s 代表一个染色体(个体)或叫一条路径。p={s0,s1,s2 …… sn}，为非 0 集合；

3) 解码，在每条路径的正确位置插入 0，形成多个弱可行解，再转化为强可行解，得到一条条满足条件的染色体。计算各染色体的适应度 f(i)，记录最好染色体 fit_max；

4) 产生新的种群：

(1) 轮盘赌选择法，选择三个父代；

(2) 对三个父代按照一定概率运用贪心 3PM 交叉算法进行交叉产生两个新个体；

(3) 对交叉后的个体运用退火选择，产生下一代的两个个体；

(4) 对选择后的两个个体按照一定的概率进行变异；

(5) 转到(1)进行下一次迭代，直到产生了 n 个个体，形成了下一代种群；

5) 当前代数加 1，当前温度 t=t*k；

6) 判断当前代中最好个体的适应度 f(i)<=最好染色体的适应度 fit_max；

(1) 如果判断是,则 tuihua=tuihua+1;

(2) 否则 tuihua=0，最好染色体的 fit_max＝当前最好个体适应度 f(i)；

7) 判断 tuihua==5||t<tf：

(1) 如果判断是，则 break，结果遗传循环；

(2)否则转到第 3)步；

中国知网 https://www.cnki.net

8) 计算经过遗传算法后得到的全局较优个体的客户距离；

9) 调用退火算法，初始化马尔科夫链的长度 L；

10) 进入模拟退火算法的迭代：

(1) 记录前代最好的个体的路径距离；

(2) 进入内循环即：马尔科夫链的循环：

a 采用 insert、swap、2-opt 三种方法产生三个临时个体，将距离最小的个体换作为新个体；

b 计算新产生的个体与前一代中个体的路径距离之差 changetd；

c 判断 changetd<0；

判断是，则接受当前新个体；否则以概率 exp (-changetd/t)接受当前新个体；

d 转到第 a 步，继续循环，直到满足结束条件，跳出内循环；

(3) 当前温度降温，t=t*k；

(4) 判断当前个体的路径距离＝＝前一代路径距离，

判断为是，则 same=same+1；否则 same=0;

(5) 判断 same= =5||t<tf：

如果判断是，则结果外循环；否则跳转到第(1)步；

11) 输出最好个体的路径及路径距离。

end

5.4 实验结果与分析

为测试算法 GCBSAGA 的性能，我们首先利用文献[67]中的测试算例进行实验，然后再用国际公认的 Min 算例[57]以及 Salhi 和 Nagy 算例[62]进行测试，这两个算例分别是图书馆应用实例，以及基本 VRP 的 benchmark 问题的扩展。

实验中的参数设置为：种群大小 inn=100，最大世代数 gnmax=200，交叉概率 pc1=0.9,pc2=0.7，变异概率 pm1=0.2, pm2=0.1，结束温度 tf=0.001，降温系数 k=0.95。

实验一：

选用文献[67]中的测试算例进行测试，测试结果如表 5-1 所示。表 1 中，N 表示所需车辆数，D 表示最短路径的距离，R 表示最短路径，G 表示找到最短路径时的世代数。

表 5-1 GCBSAGA 对文献[67]中测试算例的测试结果对比

Tab.5-1 the comparison is test results between the literature [67] and GCBSAGA

算法名称	N	D	R	G
IGA [67]	3	790	067208403510	80
GCBSAGA	3	790	048035102760	6

通过表 5-1 可知，GCBSAGA 算法在此算例中得到的结果与文献[67]中的最好结果相比，虽然在路径上有所不同，但所需车辆数及路径距离是完全相同的，这说明这两种路径都是最好解。但在求解效率上却相差很大，GCBSAGA 大概在第 6 代就能得到最优解，而 IGA 却要在第 80 代才能得到最优解，这一数据说明了 GCBSAGA 算法的准确性

中国知网 https://www.cnki.net

和高效性。

实验二：

选用国际上公认的 Min 算例进行测试，并与现有算法在这一算例上的最好解进行对比。Min 算例是一个图书馆配送的实例，从一个公共图书馆为其他 22 个分馆发送并收集图书、胶片、磁带等。Min 算法、Dethloff 算法及 IBACS 算法是国际公认的在解决 Min 算例方面的有效算法，所以这三种算法得出的最优解更是国际所公认的数据。Min 算法、Dethloff 算法、IBACS 算法及 GCBSAGA 算法的测试和对比结果如表 5-2 所示。表 5-2 中，n 表示此算例的客户数，D 表示最短路径距离，N 表示所需车辆数。

表 5-2 GCBSAGA 算法与现有算法在 Min 算例上的最好解比较

Tab.5-2 the best solution compared GCBSAGA with existing algorithms in the example Min

算例	n	Min[57]		Dethloff[61]		IBACS[68]		GCBSAGA	
		D	N	D	N	D	N	D	N
Min22	22	94	2	91	2	89	2	88	2

通过表 5-2 可以看出，GCBSAGA 算法求得的最短路径距离 88，要优于 Min 算法求得的路径 94、Dethloff 算法求得的路径 91 及 IBACS 算法求得的路径 89。GCBSAGA 算法求得的最短路径为：0 12 20 16 9 8 2 18 17 13 19 11 10 0 7 1 14 15 6 5 3 22 21 4 0，0 表示服务中心。通过这一实际性的算例，说明 GCBSAGA 算法的搜索能力和效率。

实验三：

选用国际上公认的 Salhi 和 Nagy 算例进行测试，并与现有算法在这一算例上的最好解进行比较。Salhi 和 Nagy 算例是将基本 VRP 的 benchmark 加以扩展，作为 VRPSDP 问题的测试算例，问题规模范围是 50~199。Salhi&Nagy 算法、Dethloff 算法及 Crispim&Brandão 算法是国际公认的在解决 Salhi 和 Nagy 算例方面的有效算法，所以这三种算法得出的最优解更是国际所公认的数据。Salhi&Nagy 算法、Dethloff 算法、Crispim&Brandão 算法及 GCBSAGA 算法的测试和对比结果如表 5-3 所示。表 5-3 中，n 表示此算例的客户数，D 表示最短路径距离，N 表示所需车辆数。

表 5-3 GCBSAGA 算法与现有算法在 Salhi 和 Nagy 算例[62]上的最好解比较

Tab.5-3 the best solution compared GCBSAGA with existing algorithms in the example Salhi and Nagy

算例	n	Salhi&Nagy[62]		Dethloff[61]		Crispim&Brandão[63]		GCBSAGA	
		D	N	D	N	D	N	D	N
CMT1X	50	525	5	501	3	477	3	467.62	3
CMT1Y	50	525	5	501	3	485	3	473.68	3
CMT2X	75	841	10	782	7	710	6	718.10	7
CMT2Y	75	839	10	782	7	715	6	688.67	6
CMT3X	100	829	10	847	5	744	5	739.51	5
CMT3Y	100	829	8	847	5	742	5	771.29	5
CMT12X	100	820	10	804	6	731	5	687.78	6
CMT12Y	100	825	10	825	5	860	5	669.99	6
CMT11X	120	1087	7	959	4	944	4	872.13	4
CMT11Y	120	1075	7	1070	4	1035	4	866.07	4

中国知网 https://www.cnki.net

通过表5-3可以看出，通过GCBSAGA算法求出的路径距离，要远远优于Salhi&Nagy算法和Dethloff算法分别求出的路径距离，比Crispim&Brandão算法求出的路径距离稍短。在CMT12X和CMT12Y这两个算例中，GCBSAGA算法求出的最优解的路径所需车辆数虽然比Crispim&Brandão算法求出的最优路径所需车辆数多一辆，但是总体路径却要小得多。完全符合VRPSDP问题的最终目标，车辆总行驶路径最短。

结合不同算法的优点和策略，设计出更高效的混合算法是当今优化组合领域研究的一个热点。本文通过对遗传算法和模拟退火算法进行改进，而且合理地使得这两种算法相结合，充分发挥两种算法的优点，形成一种针对VRPSDP问题的改进模拟退火遗传算法(GCBSAGA)。该算法采用非零自然数编码，从而避免了单纯实数编码带来的无效解的复杂问题，使得VRPSDP问题的编码变得方便而简洁。再引入解码机制，从而能顺利将一条路径按规则分成一些子路径，即分配给每一辆车，这样就能很方便地计算出每一辆车的行驶路程。GCBSAGA算法在进化初期，SA 温度较高，能使GA 避免产生早熟收敛，增强了GA 的全局收敛性；在进化后期，SA 温度较低，具有较强的爬山性能，加快了算法的收敛速度。而且通过国际公认的算例进行测试，证明了GCBSAGA算法的高效性，在多个实例上找到了比现在算法更优的解。

中国知网 https://www.cnki.net

第六章 结论与展望

6.1 论文小结

本文首先对遗传算法作了一个简单介绍，从生物进化的起源与发展，引导出遗传算法，得出遗传算法与生物进化的密切关系，推导出遗传算法“物竞天择、适者生存”的主要思想。通过遗传算法与进化计算相关方法的对比，反映出遗传算法与进化计算相似处和不同处，同是也反映出遗传算法的特点和优点。对遗传算法有了大概了解后，接着深入了解遗传算法，介绍了遗传算法中常用的基本概念，然后又介绍了遗传算法中的基本定理，如著名的模式定理、内存并行性、欺骗问题等最为基础的定理。接着开始介绍模拟退火遗传算法，先介绍了模拟退火算法方面的基本知识。然后介绍了基本遗传算法的步骤，每一步中常见的方法和注意点。详细介绍了适应度函数相关方法以及遗传算子等重要的知识点。对这两种算法有了初始了解后，介绍了将这两种算法相结合的模拟退火遗传算法，这种算法的国内外的研究情况，以及他们的具体流程。接着，对 TSP 这一特定问题进行分析，对遗传算法进行改进，使之能够适用于 TSP 问题。提出了一种交叉算子----贪心 3PM 交叉算子，这一算子充分考虑了父代城市之间边的关系，让子代完全继承父代中边的信息，这样大大提高了遗传算法的搜索效率。在改进的遗传算法中，巧妙地引入温度的概念，在高温时，运行遗传算法找出全局较优解，充分发挥了遗传算法的全局搜索能力；在低温时，运行模拟退火算法得到全局最优解，充分发挥了退火算法强大的局部搜索能力，避免了退火算法在高温时效率不高的问题。接着选用国际公认的 TSP 库数据，通过 Matlab7.0 平台上测试出 GCBSAGA 算法计算的实验结果，并与 TSP 库中提供的最好解进行比较，均得出了比现在解更优的解。通过这些实验数据说明了 GCBSAGA 算法的有效性。最后本文将 GCBSAGA 算法运用到配送和回收一体化的车辆路径问题(VRPSDP)中，这是一个非常实际的问题。选用国际公认的数据进行测试，并与现有算法得到的最优解进行对比，得出了比现有算法更好的解。这更加说明 GCBSAGA 算法可以运用到实际问题中，能够更好地为实际问题服务。

6.2 论文的主要创新点

(1)对遗传算法的结构进行了改进，增加了判断遗传算法搜索效率的变量，并将这一变量作为遗传算法终止的条件。这样便保留了遗传算法前期全局搜索的高效能力，而屏弃了遗传算法后期局部搜索效率低的缺点。同时对模拟退火算法的结束条件也进行了改进，增加了判断搜索效率的变量，一旦搜索效率下降或不变，说明最优解可能已经找到，便结束模拟退火算法。

(2)提出一种全新的交叉算子—贪心 3PM 交叉算子，这一算子不仅考虑城市的位置，而且也考虑了城市间的边的关系。本算子采用双向轮转的方法，使子代能够完全让子代继承父个体中边的信息。而且本算子采用 3 个父个体产生子代的方法，能够使子代中能够得到全局更好的边的信息。最后还加入退火选择这一方法，使子代的成长几乎是一代比一代强。通过实验，与现在的几个著名交叉算子进行对比，很明显发现贪心 3PM 交

中国知网 https://www.cnki.net

叉算子的收敛性要强于其它几个算子，收敛速度几乎是垂直的，搜索效率极高。

(3)将改进的遗传算法与改进的模拟退火算法结合，加入贪心 3PM 交叉算子，形成一种基于贪心 3PM 交叉算子的模拟退火遗传算法(GCBSAGA)。在这一算法中，遗传算法和模拟退火算法的结合方式与现在有算法不同，在本算法中，它们的结合方式既独立又相互联系。本文将温度这一概念加入到遗传算法中，在高温时，运行遗传算法能够快速能找出全局较优解，然后在低温时，再对全局较优解进行独立进行退火。模拟退火算法中的初始温度采用的是遗传算法结束后的剩余温度，初始解是遗传算法得到的全局较优解，这样便得退火算法一开始就在有希望的区域里搜索，搜索的效率固然会大大提高。选用通过国际公认的 TSP 库时提供的数据进行测试，找出了比现在最好解更优的解，验证了 GCBSAGA 算法的有效性。最后将这一算法运用于一个非常具有实际运用价值的问题—配送和回收一体化的车辆路径问题(VRPSDP)，选择国际公认的实例进行测试，均取得了非常好的效果。

6.3 论文存在的问题以及未来工作的展望

(1)本文提出的基于贪心 3PM 交叉算子的模拟退火遗传算法，虽然在组合优化方面体现了很好的优化性能，但在大规模组合优化数据处理上，比如 100 个城市以上，运算时间有点长，运算结果的最优解也不太稳定。

(2)论文的理论研究尚未足够，需要建立更好的模型对贪心 3PM 交叉算子和 GCBSAGA 算法进行解释。

(3)遗传算法和模拟退火算法在温度衰减上，不同数据衰减比例是多少，没有一个通用的公式来处理，现在只能设置不同的值来处理不同的数据。

以上三点只是论文存在的问题中的一部分，但是对于每一条问题的解决对于本文，对于本课题，对于整个模拟退火遗传算法的发展都具有很重大的意义。总之，利用模拟退火算法和遗传算法相结合来解决现实世界中的一些问题是一条切实可行的道路，希望以后这条道路能有更多的人去探索研究，肯定会有更多更好的研究成果。

中国知网 https://www.cnki.net

致　谢

本文是在导师葛洪伟精心指导下完成的。两年来，在学习和生活上，葛洪伟老师以其严谨求实的治学态度，高度的责任心和敬业精神，给予了我极大的帮助和鼓励，我取得的每一点成绩无不倾注了他的心血，他一丝不苟的工作作风、诲人不倦的高尚品德都值得我学习。在这里本人向葛洪伟老师表示衷心的感谢和崇高的敬意。同时衷心感谢王士同教授，以及在研究生阶段教授本人专业课的各位老师，还有专门从事研究生工作的各位老师，有了他们的辛勤工作才使得我顺利的度过这段学习时光。

另外感谢岳海兵等几位师兄在学习和生活中给予我帮助和正确引导，特别是在论文的进行阶段给予了很多帮助。感谢占东生等同学，是你们创造的良好的实验室氛围，给了我交流学习，进步的环境，感谢你们在学习中的帮助和支持。

最后，特别感谢我的父母和家人，以及我的好朋友们，他们给予我巨大的动力和支持让我继续求学，在我精神沮丧的时候给予我鼓励和勇气，在我迷失疑惑的时候给予我光明和方向，在我收获喜悦的时候给予我祝福和忠告。正是由于他们的关心和支持，我才能不断努力上进，不断取得进步！

感谢他们！

中国知网　https://www.cnki.net

参考文献

1. Chi-Hwa Song，Kynghee Lee,Won Don Lee.Extended simulated annealing for augmented Tsp and multi-salesmen TSP[C].Neural Networks，Procedings of the International joint Conference on Volume 3，2003.2340—2343.

2. Talbi H,Draa A,Batouche M.A new quantum-inspired genetic algorithm for solving the traveling salesman Problem[C] . Industrial Conference on Volume 3,2004.1192—1197.

3. KnoxJ.Tabu search performance on the symmetric traveling saleman problem[J]. Computers and Operations Research ,1994. 21(8):867 —876

4. 吴斌，史忠植.一种基于蚁群算法的 TSP 问题分段求解算法切[J].计算机学报，2001，24(12):1328—1333.

5. Yang Haiqing，Yang Haihong.An self-organizing neural network with convex-hull expanding property for TSP[C]. Neural Networks and Brain，ICNN&B'05，International Conference on volume 1,2005.379—383.

6. AransN,Altinel.IK,OommenBJA.Kohonen-like decomposition method for the Euclidean traveling salesman problem- KNIES_DECOMPOSE.IEEE Transactions on Neural Networks,2003,14（1）:869—890

7. Vasconcelos. J. A.，Ramirez. J. A., Takahashi. R. H. C. and Saldanha. R. R.: Improvements in Genetic Algorithms. IEEE Trans. Magnetics. Vol. 37. (2001) 3414—3417

8. Prügel-Bennett. A.: When a Genetic Algorithm Outperforms Hill-Climbing. Theoretical Computer Science.Vol. 320. (2004) 135—153

9. Kirkpatrick St, Gelatt C D, Vecchi M P, Optimization by simulated annealing. Science, 1983, 220. 671—680

10. Anton Dekkers, et al., Global optimization and simulated annealing, Math. Programming, 50(1991),pp.367—393.

11. Sirag D, Weisser P. Toward a unified thermo dynamic genetic operator Proceedings of the 2nd international conference on genetic a1gorithms. 1987. 116—122

12. Gu, W.-j, Zhang, R.-c, Zhao, H.-c. On fuzzy sliding mode guidance based on self-adaptive genetic annealing algorithm.IEEE Trans on SMC. 2008, 3(11):2576—2581

13. Rajapakse, M., Lin Feng. Predicting Peptide Binders of Flexible Lengths with Genetic Annealing Algorithm. IEEE Trans on SMC. 2007, 5(4): 262—267

14. 陈勇 ,唐敏 ,童若锋 ,董金祥. 基于遗传模拟退火算法的不规则多边形排样[J]. 计算机辅助设计与图形学学报.2003,(05) :598—603

15. 丁一鸣,孙瑞志. 基于遗传退火算法的网格工作流调度研究[J]. 计算机应用.

中国知网 https://www.cnki.net

2007,(S1):46—50
16.陈学松,曹炬,方仍存.遗传模拟退火算法在矩形优化排样系统中的应用[J].锻压技术,2004,(1):27—29.
17.邢文训, 谢金星. 现代优化计算方法[M]. 北京:清华大学出版社, 1999. 181 —182.
18.孟德尔等著. 遗传学经典论文选集[M]. 梁宏,王斌译,北京:科学出版社,1984.86—108
19.刘勇. 非数值并行算法(第二册)遗传算法[M]. 北京:科学出版社,2003.1—6.
20.李敏强等.遗传算法的基本理论与应用[M]. 北京:科学出版社,2002.47—96.
21.周明，孙树栋. 遗传算法原理及应用.国防工业出版社,1999.53—66
22.王小平等.遗传算法—理论、应用与软件实现[M].西安:西安交通大学出版社,2002.133—198.
23.康立山.非数值并行算法（第一册）模拟退火算法[M].北京:科学出版社,2000.22—38.
24.蔡自兴.人工智能及其应用[M]. 北京: 清华大学出版社,2007,249—283.
25.杨晓华，沈珍瑶. 智能算法及其在资源环境系统建模中的应用[M].北京: 北京师范大学出版社,2005.40—87.
26.李绍新.动态光散射测量粒径分布的格雷码编码遗传算法反演运算[J].计算物理,2008,25(3):323—330.
27.M. Hamada and N. Balakrishman. Analyzing unreplicated factorial experiments : a review wit h some new proposals[J]. Statist . Sinica ,1998 ,8 :1—41.
28.王四春.GP 算法中适应度函数的光滑拟合与调整参数方法研究[J].自动化学报.2006,(3):23—30.
29.任庆生. 对常用选择算子的分析[J].上海交通大学学报.2000.(4):103—112.
30.周 聪 郑金华. 一种改进的 TSP 启发交叉算子[J].计算机工程与应用.2008 .44 (9): 37—39
31.曲良东 何登旭. 混合变异算子的人工鱼群算法[J]. 计算机工程与应用 2008 .44 (35): 50—52
32.苑希民.神经网络和遗传算法在水科学领域的应用[M]. 北京:水利水电出版社,2002. 20—31
33.L.K. GAAFAR,S.A. MASOUD .Genetic algorithms and simulated annealing for scheduling in agile manufacturing[J]. International Journal of Production Research. 2005 .43(14):189—216
34.Lamont, O. Hiew Hong Liang, Bellgard, M.CData representation influences protein secondary structure prediction using artificial neural networks. IEEE, Trans. on Neural

中国知网 https://www.cnki.net

Networks.2001,18(10) :411—415
35.Lyons, A.M, Becker, A.J.Youngmin Lee, Metz, C, Weisser, S. Connector interconnections to transmission lines for 40 Gb/s broadband applications. 2002, 28(5):1021—1026
36.Adee,S. Reverse engineering the brain.2008,45(6):51—53
37.Lin F T, Kao C Y, HsuC C. Applying the genetic approach to simulated annealing in solving some NP hard,IEEE Trans on SMC. 1993, 23(6): l752—1767
38.Wang Jin, Xu Li, Zheng Baoyu. A Genetic Annealing Hybrid Algorithm based Clustering Strategy in Mobile Ad hoc Network., IEEE Trans on SMC. 2005,27 (1):314—318
39.周开俊,李东波. 基于遗传模拟退火算法的产品装配序列规划方法 [J]. 计算机集成制造系统. 2006 (7) , 61—66
40.阎庆,鲍远律.新型遗传模拟退火算法求解物流配送路径问题[J]. 计算机应用, 2004, 24(3), 261—263
41.陈学松,曹炬,方仍存.遗传模拟退火算法在矩形优化排样系统中的应用[J].锻压技术,2004(1):27—29.
42.杨晗,尹建伟,董金祥,罗尚虎. 分布式遗传退火算法求解分布式配置问题[J]. 计算机辅助设计与图形学学报, 2005,(06): 1335—1340
43.王宇平,李英华.求解 TSP 的量子遗传算法[J].计算机学报,2007,30(5):748—755
44.操礼程,杨依忠. 基于 GA-SA 混合算法的 VLSI 门阵列布局设计[J].计算机工程,2006,32(24):260—262
45.邹鹏,周智.求解旅行商问题的循环局部搜索算法的运行时间和性能分布分析[J].计算机学报,2006,29(1):92—99
46.Grefenstette JJ,Gopal R,Rosmaita Betal.Genetic algorithm for TSP[C]. In:Grefenstette J J eds.Proceedings of the First International Conference on Genetic Algorithms and Their Applications,Pittsburgh:Pittsburgh P A Carnegie-Mellon University,1985:160—168
47.J Horn, N Nafpliotis and D E Goldberg. A Niched Pareto Genetic Algorithm for Multiobjective Optimization[C].in Proceedings of the First IEEE conference on Evolutionary Computation, IEEE World Congress on Computational Intelligence,vol.1. Piscataway, New Jersey:IEEE Service Center,1994.82—87
48.Guo Tao, Michalewicz, Zbigniew. Inver-over operator for the TSP[C].Lecture Notes in Computer Science 1498: Proceedings of the 5 Parallel Problem Solving from Nature,1998:803—812
49.蔡之华,彭锦国.一种改进的求解 TSP 问题的演化算法[J].计算机学报,2005,28(5):823—828

中国知网 https://www.cnki.net

50.周明,孙树栋.遗传算法原理及应用[M].北京:国防工业出版社,1999.146—254
51.刘敏. 基于自适应退火遗传算法的车间日作业计划调度方法[J]计算机学报 2007,7(5): 1164—1172
52.DeJone K A. Genetic Algorithms: A 25 Year Perspective, In: Computational Intelligence Imitating Life. Eds. J M Zurada et al, New York: IEEE Press, 1994.83(11):1588—1602
53.http://www.iwr.uni-heidelberg.de/groups/compot/soft-ware/tsplib95/tsp
54.刘浩, 袁健, 卢厚清. 两种类型车辆随机需求路由问题[J]. 南京航空航天大学学报, 2001, 33(2): 155—158.
55.Dantzig GB, Ramser JH. The truck dispatching problem[J]. Management Science, 1959, 6(1):80—91.
56.陆琳,谭清美. 基于自感应蚁群算法的 VRPSDP 问题研究[J].中国管理科学,2007.15(2):97—103.
57.Min H. The multiple vehicle routing problem with simultaneous delivery and pickup points[J]. Transportation Research A, 1989, 23A(5):377-386.
58.Mosheiov G. The traveling salesman problem with pick-up and delivery[J]. European Journal of Operational Research, 1994, 79(2):299-310.
59.Privé J, Renaud J, Boctor F, Laporte G. Solving a vehicle routing problem arising in soft drink distribution[J]. Journal of the Operational Research Society, 2006, 57(9):1045–1052.
60.Wasner M, Zapfel G. An integrated multi-depot hub-location vehicle routing model for network planning of parcel service[J]. International Journal of Production Economics, 2004, 90(3): 403-419.
61.Dethloff J. Vehicle routing and reverse logistics: the vehicle routing problem with simultaneous delivery and pick-up[J]. OR Spektrum, 2001, 23(1):79–96.
62.Salhi S, Nagy G. A cluster insertion heuristic for single and multiple depot vehicle routing problem with backhauling[J]. Journal of the Operational Research Society, 1999, 50(10):1034-1042.
63.Crispim J, Brandão J. Metaheuristics applied to mixed and simultaneous extensions of vehicle routing problems with backhauls[J]. Journal of the Operational Research Society, 2005, 56(11):1296–1302.
64.Tang Montané FA, Galvão RD. A tabu search algorithm for the vehicle routing problem with simultaneous pick-up and delivery service[J]. Computers & Operations Research, 2006, 33(3):595–619.
65.Chen JF, Wu TH. Vehicle routing problem with simultaneous deliveries and pickups[J]. Journal of the Operational Research Society, 2006, 57(5):579-587.

中国知网 https://www.cnki.net

66. Bianchessi N, Righini G. Heuristic algorithms for the vehicle routing problem with simultaneous pick-up and delivery[J]. Computers & Operations Research, 2007, 34(2):578–594.

67. Erbao Cao, Mingyoung Lai. An Improved Genetic Algorithm for the Vehicle Routing Problem with Simultaneous Delivery and Pickup[J]. The Sixth Wuhan International Conference on E-Business － Innovation Management Track. 2007,50(9),2100－2106

68. Ping Chen, Houkuan Huang and Xingye Dong. An Ant Colony System Based Heuristic Algorithm for the Vehicle Routing Problem with Simultaneous Delivery and Pickup[J]. 2007 Second IEEE Conference on Industrial Electronics and Applications. 2007,26(52):136－141.

中国知网 https://www.cnki.net

附录： 作者在攻读硕士学位期间发表的论文

1. 王银年，葛洪伟，求解 TSP 问题的改进模拟退火遗传算法，计算机工程与应用(已录用)

2. 葛洪伟，王银年，求解 VRPSDP 问题的改进模拟退火遗传算法，计算机工程与应用(已录用)

中国知网 https://www.cnki.net